Chapitre I : Introduction à la modélisation linéaire

Dr. MERGANE

Université du Sine Saloum El-Hâdj Ibrahima NIASS

2024-2025

USSEIN

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Modèle

Définition et intérêts

☞ Représentation simplifiée (caricature) de la réalité.

☞ Technique qui permet de chercher, de quantifier des relations existantes entre variables.

☞ Permet de comprendre un problème et de pouvoir faire des prévisions.

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Présentation du modèle

Soient Y, x_1, x_2, $\cdots$, x_p des variables.

On cherche à exprimer Y (qui est quantitative) en fonction des autres variables càd trouver une fonction g telle que

$$Y \approx g(x_1, x_2, \cdots, x_p)$$

Présentation du modèle

Soient Y, x_1, x_2, $\cdots$, x_p des variables.

On cherche à exprimer Y (qui est quantitative) en fonction des autres variables càd trouver une fonction g telle que

$$Y \approx g(x_1, x_2, \cdots, x_p)$$

En admettant que Y est **aléatoire** et les x_i **déterministes**, l'écriture précédente devient

$$Y = \underbrace{g\left(x_1, x_2, \cdots, x_p\right)}_{\text{Partie fixe déterministe}} + \underbrace{\epsilon}_{\text{Partie aléatoire}}$$

Il faut ensuite déterminer la façon dont les x_i sont liées à Y : **spécification des paramètres fixes** (inconnus) du modèle. Notons les par $\beta_1, \beta_2, \cdots, \beta_p$.

Définition

On parle de **modèle linéaire**, *un modèle dans lequel les paramètres interviennent linéairement (pas les x_i).*

Ecriture du modèle linéaire

$$Y = \beta_1 g_1(x_1, \cdots, x_p) + \cdots + \beta_p g_p(x_1, \cdots, x_p) + \epsilon$$

Exemple (Modèle linéaire)

- $Y = \beta_0 + \beta_1 x + \epsilon$
- $Y = \beta_0 + \beta_1 e^{x^2} + \beta_2 \log(|x|) x + \epsilon$

Exemple (Modèle non linéaire)

- $Y = \beta_0 + e^{-\beta_1 x} x + \epsilon$
- $Y = \beta_0 + \beta_1 x + \log(\beta_2 + x) + \epsilon$

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Vocabulaire des variables

Selon les domaines :

$x_1, \cdots, x_p$	Y
Variables explicatives	Variable à expliquer
Variables de contrôle	Variable réponse
Variables indépendantes	Variable dépendante
Prédictives	A prédire
Exogènes	Endogène

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

La partie aléatoire du modèle

- La partie aléatoire du modèle est appelée **erreur.**
- Elle représente tout ce qui est ignoré
- Cristalise toutes les insuffisances du modèle :
  - Fluctuations liées à l'échantillonnage
  - Variables non prises en compte dans le modèle
  - La spécifiction de g n'est pas rigoureusement exacte
  - etc.

Hypothèses sur les erreurs ϵ

Hypothèses sur les erreurs ϵ

- **Normalité :** Les erreurs doivent être distribuées normalement.
  Un phénomène suit une loi normale, s'il est la résultante d'un grand nombre d'effets et petits qui s'ajoutent.
- **Homoscédasticité :** Les erreurs doivent être du même ordre de grandeur.
- **Indépendance (non corrélation) :** L'erreur commmise sur une mesure ne doit pas être liée à l'erreur commise sur une autre mesure.

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Classification des modèles linéaires

Selon la nature des variables explicatives, les modèles linéaires portent différents noms.

Variables explicatives	**Nom de l'analyse**
1 quantitative	Régression linéaire simple
Plusieurs variables quantitatives	Régression linéaire multiple
1 ou plusieurs variables qualitatives	Analyse de variance
1 quantitative et plusieurs qualitatives	Analyse de covariance
Plusieurs quantitatives et plusieurs qualitatives	Modèle linéaire

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Phases d'une régression

- **Modélisation**
- **Estimations des paramètres**
- **Validation du modèle**

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Loi normale ou loi de Laplace-Gauss

Définition

Soient $\mu \in \mathbb{R}$, $\sigma > 0$. On dit que la v.a. X suit une loi normale de moyenne μ et de variance σ^2, et on note $X \sim \mathcal{N}\left(\mu, \sigma^2\right)$, lorsque la densité de X est de la forme :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \forall x \in \mathbb{R}.$$

Loi normale ou loi de Laplace-Gauss

Définition

Soient $\mu \in \mathbb{R}$, $\sigma > 0$. On dit que la v.a. X suit une loi normale de moyenne μ et de variance σ^2, et on note $X \sim \mathcal{N}\left(\mu, \sigma^2\right)$, lorsque la densité de X est de la forme :

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \forall x \in \mathbb{R}.$$

☞ La loi normale est la loi centrale. Elle sert à modéliser les effets additifs de petits phénomènes aléatoires indépendants et répétés.

Propriété

Soient $X_1, X_2, \cdots, X_n$, *une suite de v.a. indépendantes ;* $\alpha_1, \alpha_2, \cdots, \alpha_n$, *une suite de nombres réels non nuls.*
Si pour tout i *dans* $\{1, 2, \cdots, n\}$, *on a* $X_i \sim \mathcal{N}\left(\mu_i, \sigma_i^2\right)$, *alors*

$$\sum_{i=1}^{n} \alpha_i X_i \sim \mathcal{N}\left(\sum_{i=1}^{n} \alpha_i \mu_i, \sum_{i=1}^{n} \alpha_i^2 \sigma_i^2\right).$$

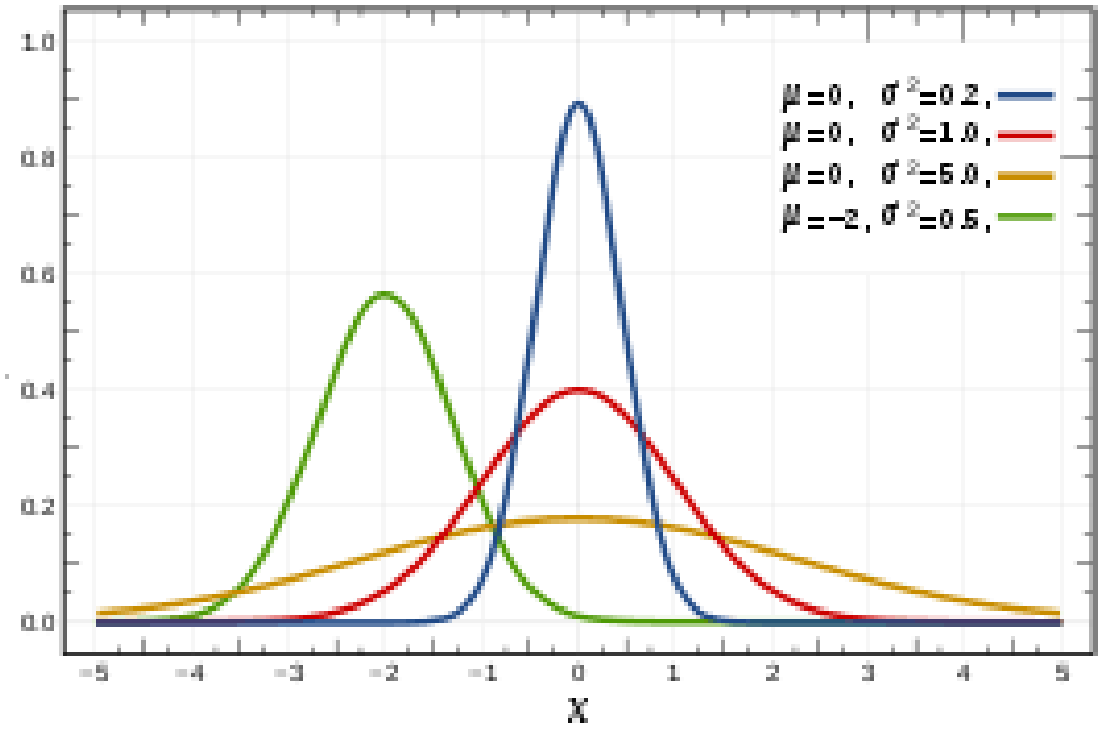

Fig.: Densité de la loi $\mathcal{N}(\mu, \sigma^2)$

Loi normale standard

Définition

Une loi normale de moyenne nulle et de variance un est appelée **loi normale centrée et réduite ou loi normale standard.**

Loi normale standard

Définition

Une loi normale de moyenne nulle et de variance un est appelée **loi normale centrée et réduite ou loi normale standard.**

Proposition

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, *alors*

$$\frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$$

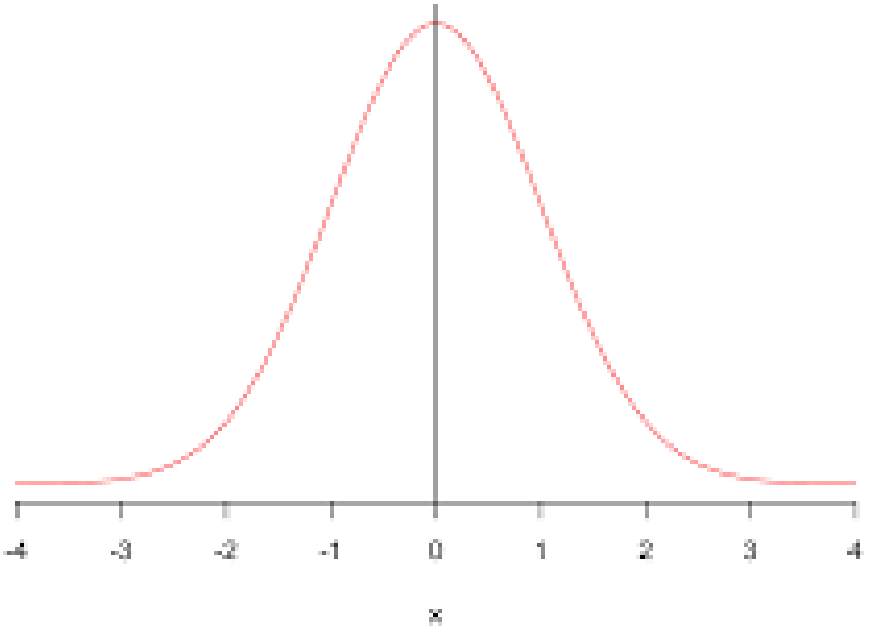

Fig.: Densité de la loi $\mathcal{N}(0, 1)$

Loi du khi-deux

Définition

On appelle loi du **khi-deux ou khi carré** *à n degrés de liberté, la loi de la somme de carrés de n lois normales centrées réduites indépendantes.*

Soit $X_1, X_2, \cdots, X_n$, une suite de v.a. iid de la loi $\mathcal{N}(0,1)$, alors

$$\sum_{i=1}^{n} X_i^2 \sim \chi_n^2.$$

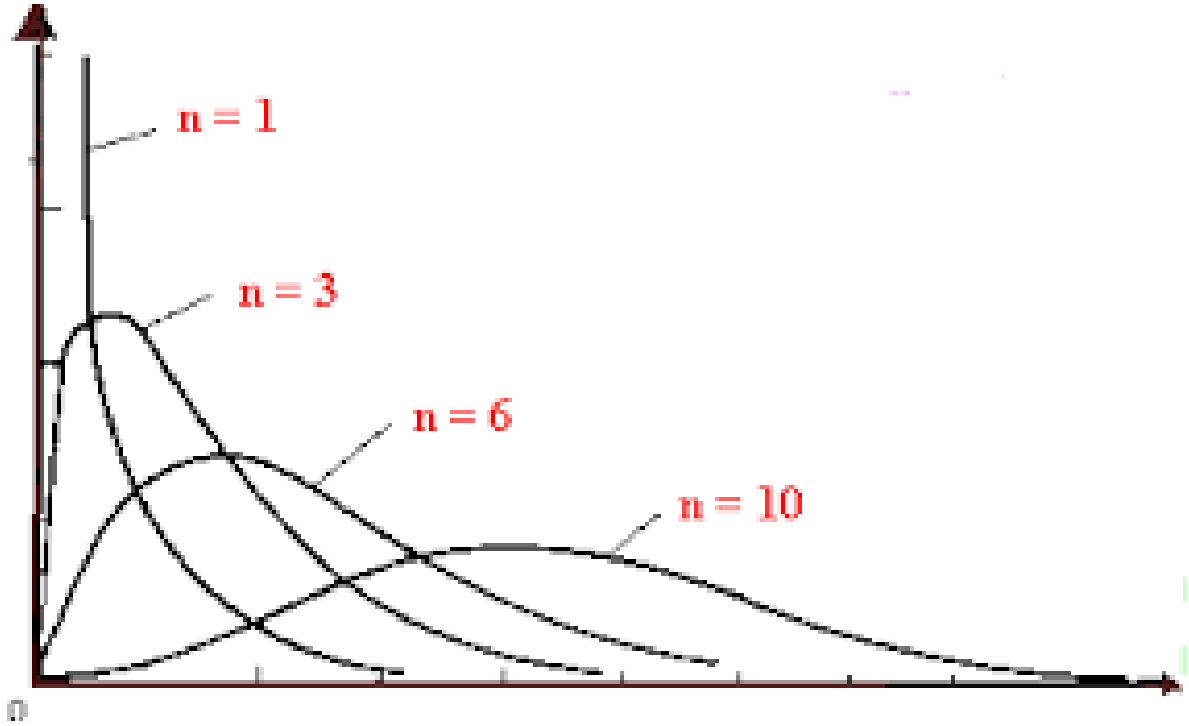

Fig.: Densité de la loi du χ^2_n

Loi de Student

Définition

On appelle loi de **Student** *à n degrés de liberté, la loi de probabilité faisant intervenir le quotient entre une variable suivant une loi normale standard et la racine carrée d'une variable distribuée suivant la loi du khi-deux à n degrés de liberté.*

Soient X et Y deux variables aléatoires indépendantes telles que $X \sim \mathcal{N}(0,1)$, $Y \sim \chi^2_n$. Alors

$$\frac{X}{\sqrt{Y/n}} \sim \mathcal{S}t(n)$$

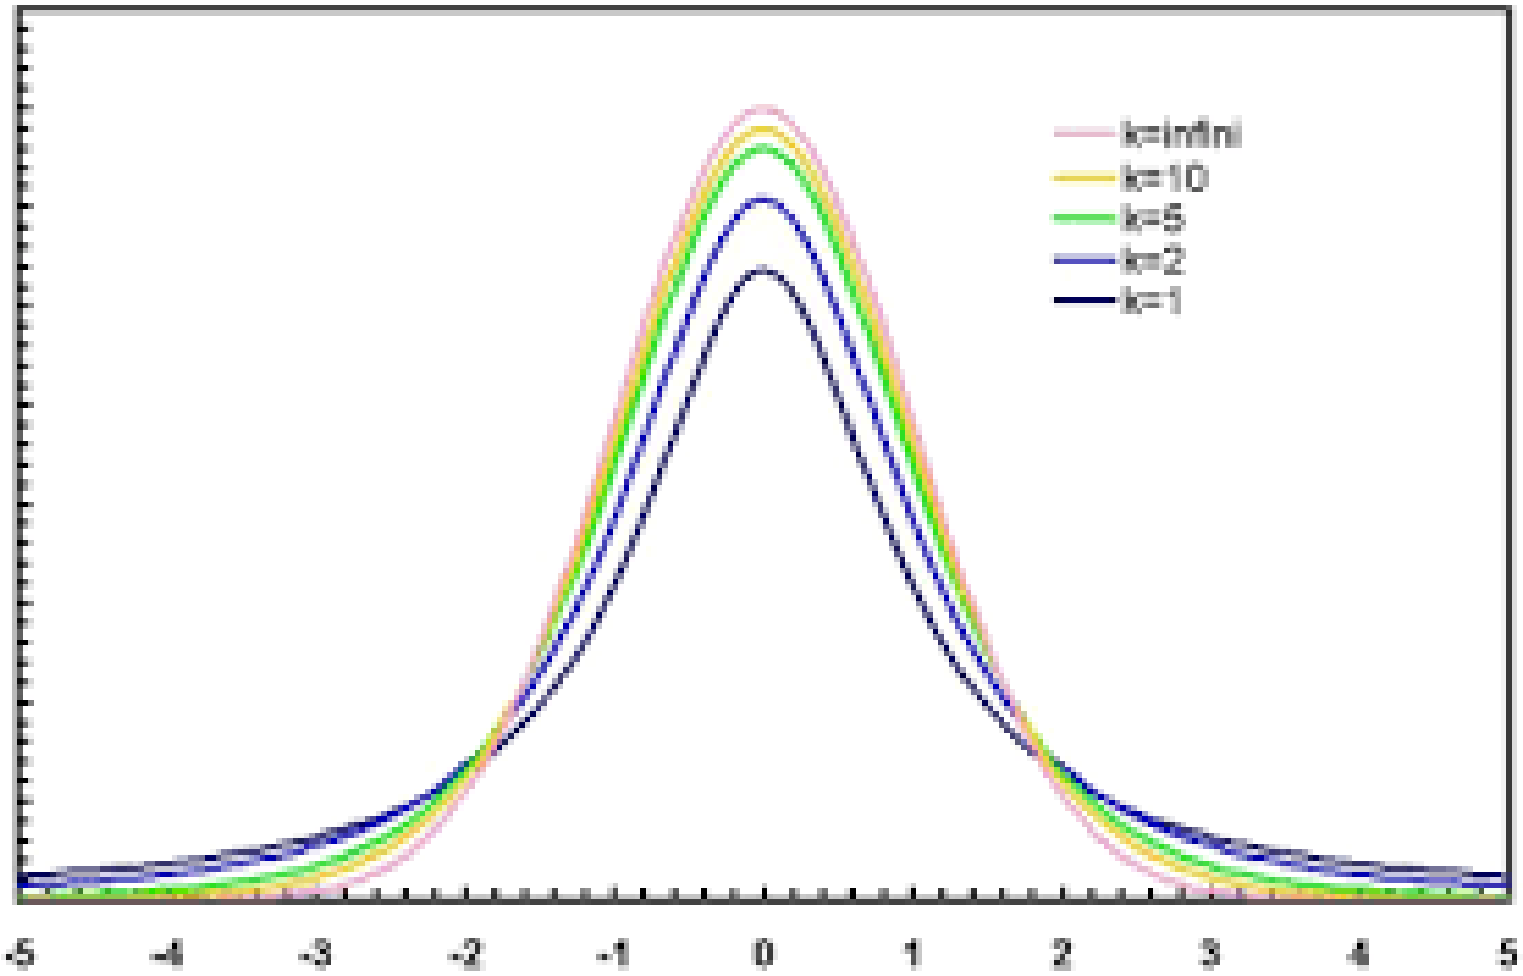

Fig.: Densité de la loi de $\mathcal{S}t(k)$

Loi de Fisher

Définition

La loi de Fisher ou de Fisher-Snedecor est le rapport de deux lois indépendantes du chi-deux divisées par leurs nombres de degrés de liberté.

Soient X et Y deux variables aléatoires indépendantes telles que : $X \sim \chi^2_n$ et $Y \sim \chi^2_m$, alors

$$\frac{X/n}{Y/m} \sim \mathcal{F}(n, m)$$

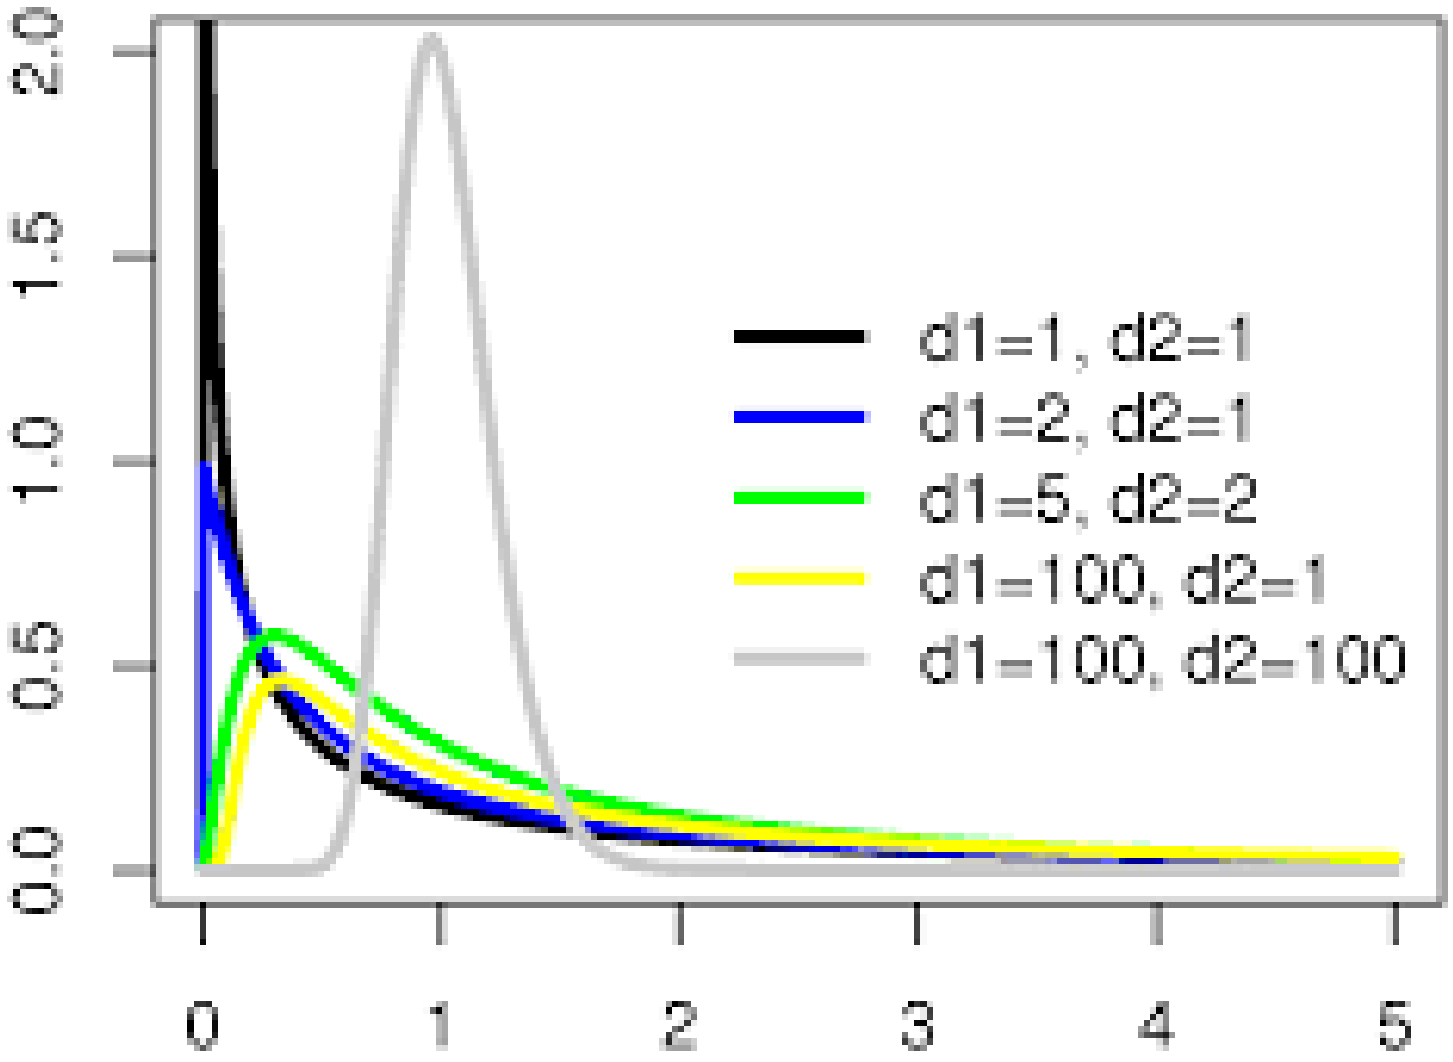

Fig.: Densité de la loi $\mathcal{F}(d1, d2)$

Théorèmes

Soient $X_1, X_2, \cdots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant une loi de probabilité de moyenne μ et de variance σ^2.
On note par

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \text{ et } S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

la moyenne et variance empirique.

Théorème (Loi des Grands Nombres)

Pour de grandes valeurs de n, nous avons presque sûrement :

$$\overline{X} \approx \mu$$

Théorème (Loi des Grands Nombres)

Pour de grandes valeurs de n, nous avons presque sûrement :

$$\overline{X} \approx \mu$$

Théorème (Théorème Limite Central)

Pour de grandes valeurs de n, nous avons l'approximation suivante :

$$\sqrt{n}\frac{\overline{X} - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

Théorème (de Fisher)

On admet que les X_i $(i = 1, \cdots, n)$ sont gaussiennes.

1. $\overline{X}$ *et* S^2 *sont indépendantes.*
2. $$\frac{n}{\sigma^2} S^2 \sim \chi^2_{n-1}.$$
3. $$\sqrt{n}\frac{\overline{X} - \mu}{S} \sim \mathcal{S}t\,(n-1)\,.$$

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Estimations

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu.

Estimations

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu.

☞ **L'estimation ponctuelle :**

Estimations

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu.

☞ **L'estimation ponctuelle :** on donne des valeurs approximatives aux paramètres d'une population à l'aide d'un échantillon de n observations issues de cette population. On peut se tromper sur les valeurs exactes à estimer, mais on donne les « meilleurs valeurs » possibles que l'on peut supposer.

Estimations

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu.

☞ **L'estimation ponctuelle :** on donne des valeurs approximatives aux paramètres d'une population à l'aide d'un échantillon de n observations issues de cette population. On peut se tromper sur les valeurs exactes à estimer, mais on donne les « meilleurs valeurs » possibles que l'on peut supposer.

☞ **L'estimation par intervalle de confiance :**

Estimations

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu.

☞ **L'estimation ponctuelle :** on donne des valeurs approximatives aux paramètres d'une population à l'aide d'un échantillon de n observations issues de cette population. On peut se tromper sur les valeurs exactes à estimer, mais on donne les « meilleurs valeurs » possibles que l'on peut supposer.

☞ **L'estimation par intervalle de confiance :** on cherche un intervalle recouvrant « très vraisemblablement » la vraie valeur du paramètre théorique de la population.

Méthodes de recherche d'un estimateur

Plusieurs méthodes

- Méthode des moments
- Méthode du maximum de vraisemblance
- Méthode des moindres carrés
- etc.

Plan

1. Modèle
   - Définition
   - Présentation du modèle
   - Vocabulaire des variables
   - La partie aléatoire du modèle
   - Classification des modèles linéaires
   - Phases d'une régression
2. Rappel
   - Lois usuelles
     - Loi normale
     - Loi du khi-deux
     - Loi de Student
     - Loi de Fisher
     - Théorèmes fondamentaux
   - Estimations
   - Tests d'hypothèses

Définition

Définition

Un test d'hypothèse est un mécanisme qui permet au vu des données d'un échantillon, de rejeter ou non une hypothèse.

On distinguera deux classes de tests :

- *si le test est basé sur un ou plusieurs paramètres statistiques, alors il est* **paramétrique** *;*
- *sinon, le test est dit* **non paramétrique.**

Hypothèses

Définition

Une hypothèse statistique H est une affirmation qui concerne :

1. *La valeur d'un paramètre (moyenne, variance, proportion, etc.)*
2. *L'égalité des paramètres de deux (ou plusieurs) distributions (deux moyennes, deux variances, etc.)*
3. *La forme d'une distribution.*

Hypothèses

Hypothèses

Il existe deux types d'hypothèses qui sont exclusives.

☞ L'hypotèse principale notée par H_0 est appelée **hypothèse nulle.** Elle est celle que l'on désire contôler.

☞ La deuxième est celle qui correspond à l'hypothèse de recherche. On l'appelle **la contre hypothèse ou hypothèse alternative** et elle est notée par H_1. On conclut que celle-ci est « vraie » si les données de l'échantillon permettent de rejeter la première (H_0).

Les erreurs

Le rejet ou non de l'hypothèse nulle conduit à deux types d'erreurs.

Les erreurs

Le rejet ou non de l'hypothèse nulle conduit à deux types d'erreurs.

- L'erreur de première espèce ou de type I est due au fait de rejeter à tord H_0 (rejeter H_0 sachant qu'elle est vraie). On associe à cette erreur la propabilité suivante :

$$\alpha = \mathbb{P}\left(\text{Rejeter } \mathrm{H}_0 \,|\, \mathrm{H}_0 \text{ est vraie}\right).$$

  La valeur de α est généralement fixée a priori et son choix est lié au risque que l'on accepte de prendre dans la décision, on l'appelle aussi **le seuil de signification ou de significativité.**

- L'erreur de seconde espèce ou de type II est celle qu'on commet en acceptant l'hypothèse nulle sachant qu'elle est fausse. Sa probabilité correspondante est

$$\beta = \mathbb{P}\left(\text{Choisir } \mathrm{H}_0 \,|\, \mathrm{H}_0 \text{ est fausse}\right).$$

Les erreurs

Les différentes probabilités obtenues dans la prise de décision sont résumées dans le tableau suivant :

Décision \ Réalité	H_0 est vraie	H_0 est fausse
Choisir H_0	$1-\alpha$	β
Rejeter H_0	α	$1-\beta$

La quantité $1-\beta$ est appelée **puissance du test.**

La statistique de test

On appelle statistique de test S la variable de décision. C'est une statistique dont la loi est parfaitement connue sous H_0 et sa réalisation s_{obs} permettra de décider ou non du rejet de H_0.

Région et seuil critique

La région critique W d'un test est l'ensemble des valeurs possibles de la statistique provenant de l'échantillon aléatoire qui entraînent le rejet de H_0 au niveau de signification α. Le seuil critique s_c est la valeur limite à partir de laquelle on pourra rejeter H_0 avec un seuil de significativité donné. Il est défini à partir de l'erreur de type I :

$$\alpha = \mathbb{P}\left(\text{rejeter } \mathrm{H}_0 \,|\, \mathrm{H}_0 \text{ est vraie}\right).$$

Le complémentaire de la région critique $\overline{W}$ est appelé **région de non rejet ou d'acceptation.**

La p-value

La *p*-value est le plus petit seuil de significativité conduisant au rejet de l'hypothèse nulle. Elle est évaluée à partir des observations et de leurs propriétés distributionnelles sous H_0.

La règle de décision

Il existe deux manières équivalantes de prendre une décision. La première est de voir si la réalisation s_{obs} de la statistique de test S est dans la zone de rejet W ou pas. Dans ce cas on a la décision suiante :

- si $s_{obs} \in W$ alors H_0 est rejetée
- sinon, elle n'est pas rejetée.

La deuxième consiste à comparer la p-value (pv) au seuil de signification α. La plupart des logiciels statistiques fournissent la p-value au lieu de la région critique. Elle consiste à rejeter H_0 lorsque $pv < \alpha$.

Résumé d'un test statistique

Les étapes

Un test d'hypothèse est une démonstration par absurde. En effet, on suppose toujours que l'hypothèse nulle est vraie et on cherche à trouver une contradiction au vu des données de l'échantillon avec un seuil de signification α donné.

Si l'hypothèse nulle est rejetée, on dit que le test est significatif. Sinon, il est dit non significatif pour dire que les observations ne sont pas en contradiction avec l'hypothèse nulle.

La démarche d'un test statistique est la suivante :

Résumé d'un test statistique

Les étapes

Un test d'hypothèse est une démonstration par absurde. En effet, on suppose toujours que l'hypothèse nulle est vraie et on cherche à trouver une contradiction au vu des données de l'échantillon avec un seuil de signification α donné.

Si l'hypothèse nulle est rejetée, on dit que le test est significatif. Sinon, il est dit non significatif pour dire que les observations ne sont pas en contradiction avec l'hypothèse nulle.

La démarche d'un test statistique est la suivante :

- Formulation des hypothèses

Résumé d'un test statistique

Les étapes

Un test d'hypothèse est une démonstration par absurde. En effet, on suppose toujours que l'hypothèse nulle est vraie et on cherche à trouver une contradiction au vu des données de l'échantillon avec un seuil de signification α donné.

Si l'hypothèse nulle est rejetée, on dit que le test est significatif. Sinon, il est dit non significatif pour dire que les observations ne sont pas en contradiction avec l'hypothèse nulle.

La démarche d'un test statistique est la suivante :

- Formulation des hypothèses
- Recherche de la statistique de test

Résumé d'un test statistique

Les étapes

Un test d'hypothèse est une démonstration par absurde. En effet, on suppose toujours que l'hypothèse nulle est vraie et on cherche à trouver une contradiction au vu des données de l'échantillon avec un seuil de signification α donné.

Si l'hypothèse nulle est rejetée, on dit que le test est significatif. Sinon, il est dit non significatif pour dire que les observations ne sont pas en contradiction avec l'hypothèse nulle.

La démarche d'un test statistique est la suivante :

- Formulation des hypothèses
- Recherche de la statistique de test
- Détermination de la région de rejet ou calcul de la p-value

Résumé d'un test statistique

Les étapes

Un test d'hypothèse est une démonstration par absurde. En effet, on suppose toujours que l'hypothèse nulle est vraie et on cherche à trouver une contradiction au vu des données de l'échantillon avec un seuil de signification α donné.

Si l'hypothèse nulle est rejetée, on dit que le test est significatif. Sinon, il est dit non significatif pour dire que les observations ne sont pas en contradiction avec l'hypothèse nulle.

La démarche d'un test statistique est la suivante :

- Formulation des hypothèses
- Recherche de la statistique de test
- Détermination de la région de rejet ou calcul de la p-value
- Prise de décision

Zone de non acceptation / p-value

La forme de la région de rejet (W) dépend de la nature du test (unilatéral ou bilatéral).
Supposons que S est la statistique de test et s_{obs} sa réalisation. Notons par q_β le quantile d'ordre β de la loi de S sous H_0.

Soit α le seuil de significativité du test.

Hypothèse alternative H_1	Zone de rejet W	p-value pv
$H_1 : \theta > \theta_0$	$W =]q_{1-\alpha} ; +\infty[$	$pv = \mathbb{P}_{H_0}(S > s_{obs})$
$H_1 : \theta < \theta_0$	$W =]-\infty ; q_\alpha[$	$pv = \mathbb{P}_{H_0}(S < s_{obs})$
$H_1 : \theta \neq \theta_0$	$W =]-\infty; q_{\frac{\alpha}{2}}[\cup]q_{1-\frac{\alpha}{2}} ; +\infty[$	$pv = \mathbb{P}_{H_0}(\lvert S\rvert > \lvert s_{obs}\rvert)$