Chapitre II : Modèle linéaire simple

Dr. MERGANE

Université du Sine Saloum El-Hâdj Ibrahima NIASS

2024-2025

USSEIN

Chapitre II : Modèle Linéaire Simple

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Exemple Introductif [Rendements agricoles]

Pour étudier la relation qui peut exister entre le rendement de blé (en kilogramme) et la quantité d'engrais utilisées (en quintal), des agronomes reccueillent sur $n = 7$ parcelles la quantité x_i utilisée sur la $i^{\text{ième}}$ parcelle, et le rendement de blé y_i obtenu sur la $i^{\text{ième}}$ parcelle.
Les données sont les n couples (x_i, y_i) et sont résumées dans le tableau ci-dessous.

N° parcelle	1	2	3	4	5	6	7
Eng. x_i (q)	100	200	300	400	500	600	700
Rend. y_i (kg)	40	50	50	70	65	65	80

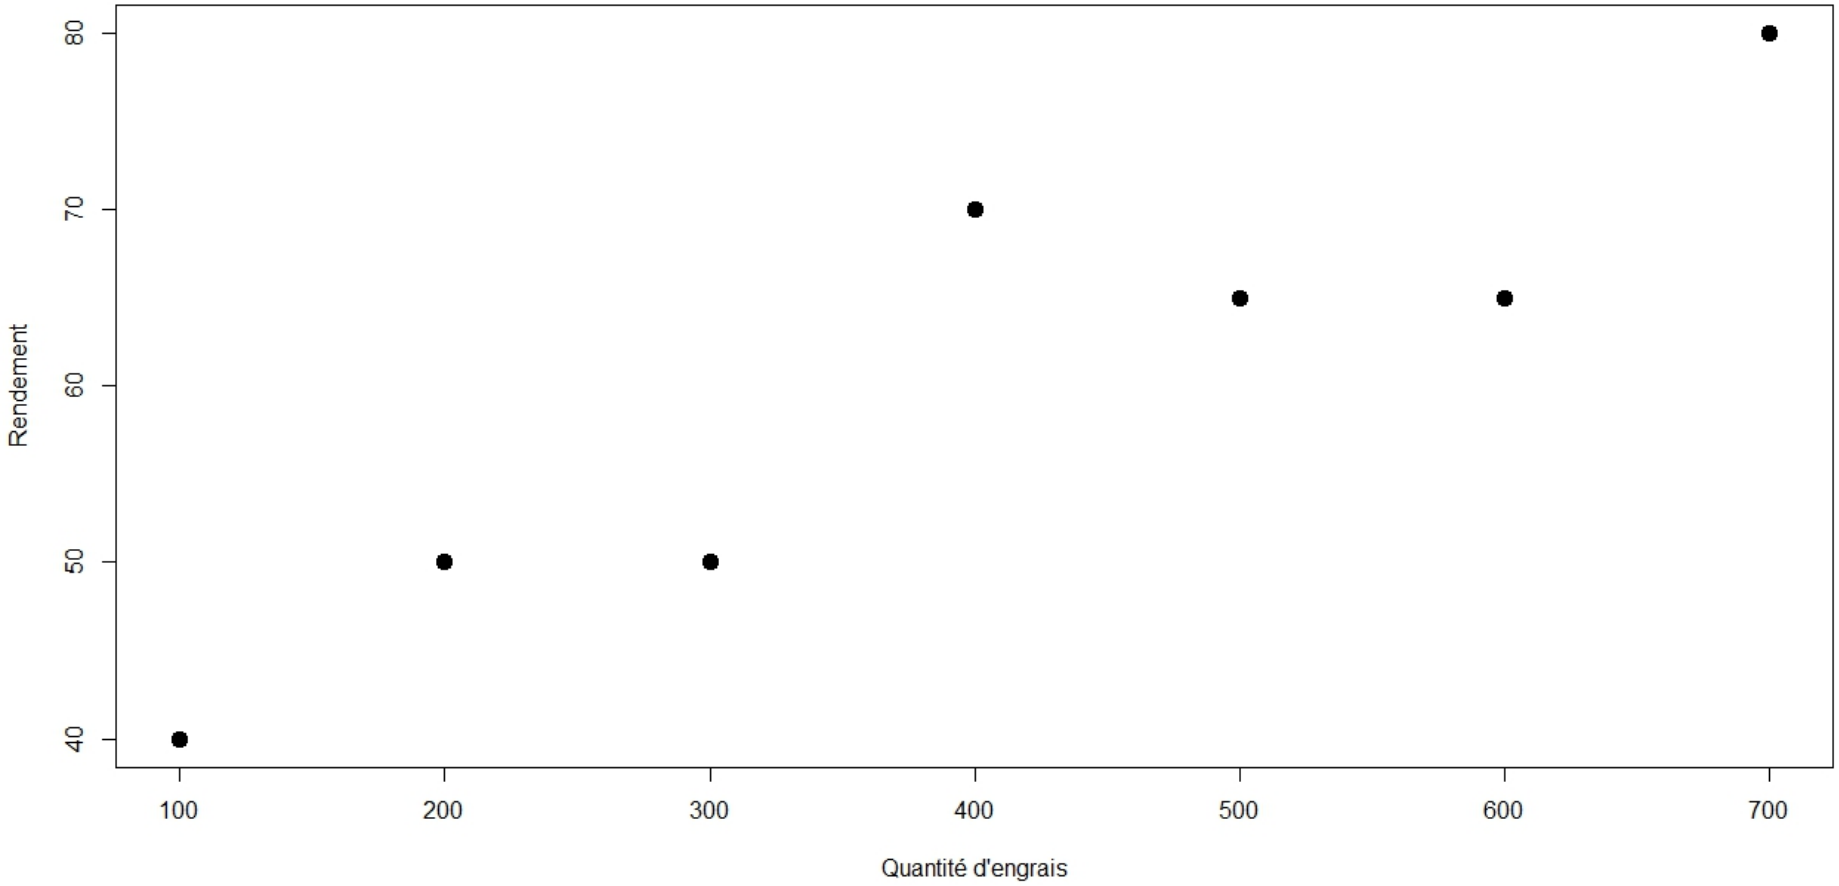

Fig.: Nuage de points

- $\overline{x}$
- $\overline{y}$
- S_x^2
- S_y^2
- S_{xy}
- r_{xy}
- En admetant que les données sont gaussiennes, tester la dépendance linéaire. On peut utiliser le fait que

$$T = \frac{r_{xy}}{\sqrt{\frac{1-r_{xy}^2}{n-2}}} \sim \mathcal{S}t(n-2)$$

Définition

Définition

Soit n couples $(x_i, y_i)_{i=1,\cdots,n}$ correspondant à n valeurs observées des variables $(x_i, Y_i)_{i=1,\cdots,n}$ quantitatives.

Définition

Par **régression linéaire simple,** *nous entendons le modèle suivant*

$$y_i = ax_i + b + \epsilon_i, \;\; i = 1, \cdots, n.$$

Définition

Soit n couples $(x_i, y_i)_{i=1,\cdots,n}$ correspondant à n valeurs observées des variables $(x_i, Y_i)_{i=1,\cdots,n}$ quantitatives.

Définition

Par **régression linéaire simple,** *nous entendons le modèle suivant*

$$y_i = ax_i + b + \epsilon_i, \;\; i = 1, \cdots, n.$$

- *Y est appelée variable à* **expliquer, dépendante**
- *x est appelée variable* **explicative, indépendante**
- *a et b sont des* **paramètres fixes** *et inconnus du modèle ;*
- *Les ϵ_i représentent les termes* **d'erreurs** *(aléatoires).*

Objectifs

La régression linéaire est une méthode statistique permettant :

- ☞ D'étudier la **dépendance linéaire** de la variable Y par rapport à la variable x qui est **contrôlée** par l'expérimentateur ;
- ☞ **Prédire** la valeur de Y à partir d'une nouvelle valeur de x.

Hypothèses

Hypothèses

✌ Permettent de déterminer les propriétés des estimateurs afin de mettre en place des outils de statistique inférentielle (Intervalles de confiance, Tests d'hypothèses).

Hypothèses

✌ Permettent de déterminer les propriétés des estimateurs afin de mettre en place des outils de statistique inférentielle (Intervalles de confiance, Tests d'hypothèses).

Hypothèses

- $\mathbf{H}_1$. **Normalité :** Les ϵ_i sont des variables aléatoires distribuées suivant une loi normale.
- $\mathbf{H}_2$. **Homoscédasticité :** Les erreurs ont tous la même variance.
- $\mathbf{H}_3$. **Décorrélation (Indépendance) :** Les erreurs sont totalement décorrélées entre elles.

Remarque

1. $\epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$ *ou encore* $Y_i \overset{iid}{\sim} \mathcal{N}(ax_i + b, \sigma^2)$

2. $$cov(\epsilon_i, \epsilon_j) = \begin{cases} \sigma^2 & si\ i = j\ (Homoscédasticité) \\ 0 & sinon\ (Non\ corrélation\ des\ erreurs) \end{cases}$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Méthodes des Moindres Carrés Ordinaires

Définition

On appelle estimateur des Moindres Carrés Ordinaires (MCO) $\widehat{a}$ *et* $\widehat{b}$*, les valeurs minimisant la fonction :*

$$f(a,b) = \sum_{i=1}^{n} (y_i - ax_i - b)^2$$

Méthodes des Moindres Carrés Ordinaires

Définition

On appelle estimateur des Moindres Carrés Ordinaires (MCO) $\widehat{a}$ et $\widehat{b}$, les valeurs minimisant la fonction :

$$f(a,b) = \sum_{i=1}^{n} (y_i - ax_i - b)^2$$

✌ La droite des moindres carrés minimise la somme des carrés des distances verticales des points (x_i, y_i) du nuage à la droite ajustée $y = \widehat{a}x + \widehat{b}$. Autrement dit, on cherche la droite en x qui passe globalement le plus près possible des y_i.

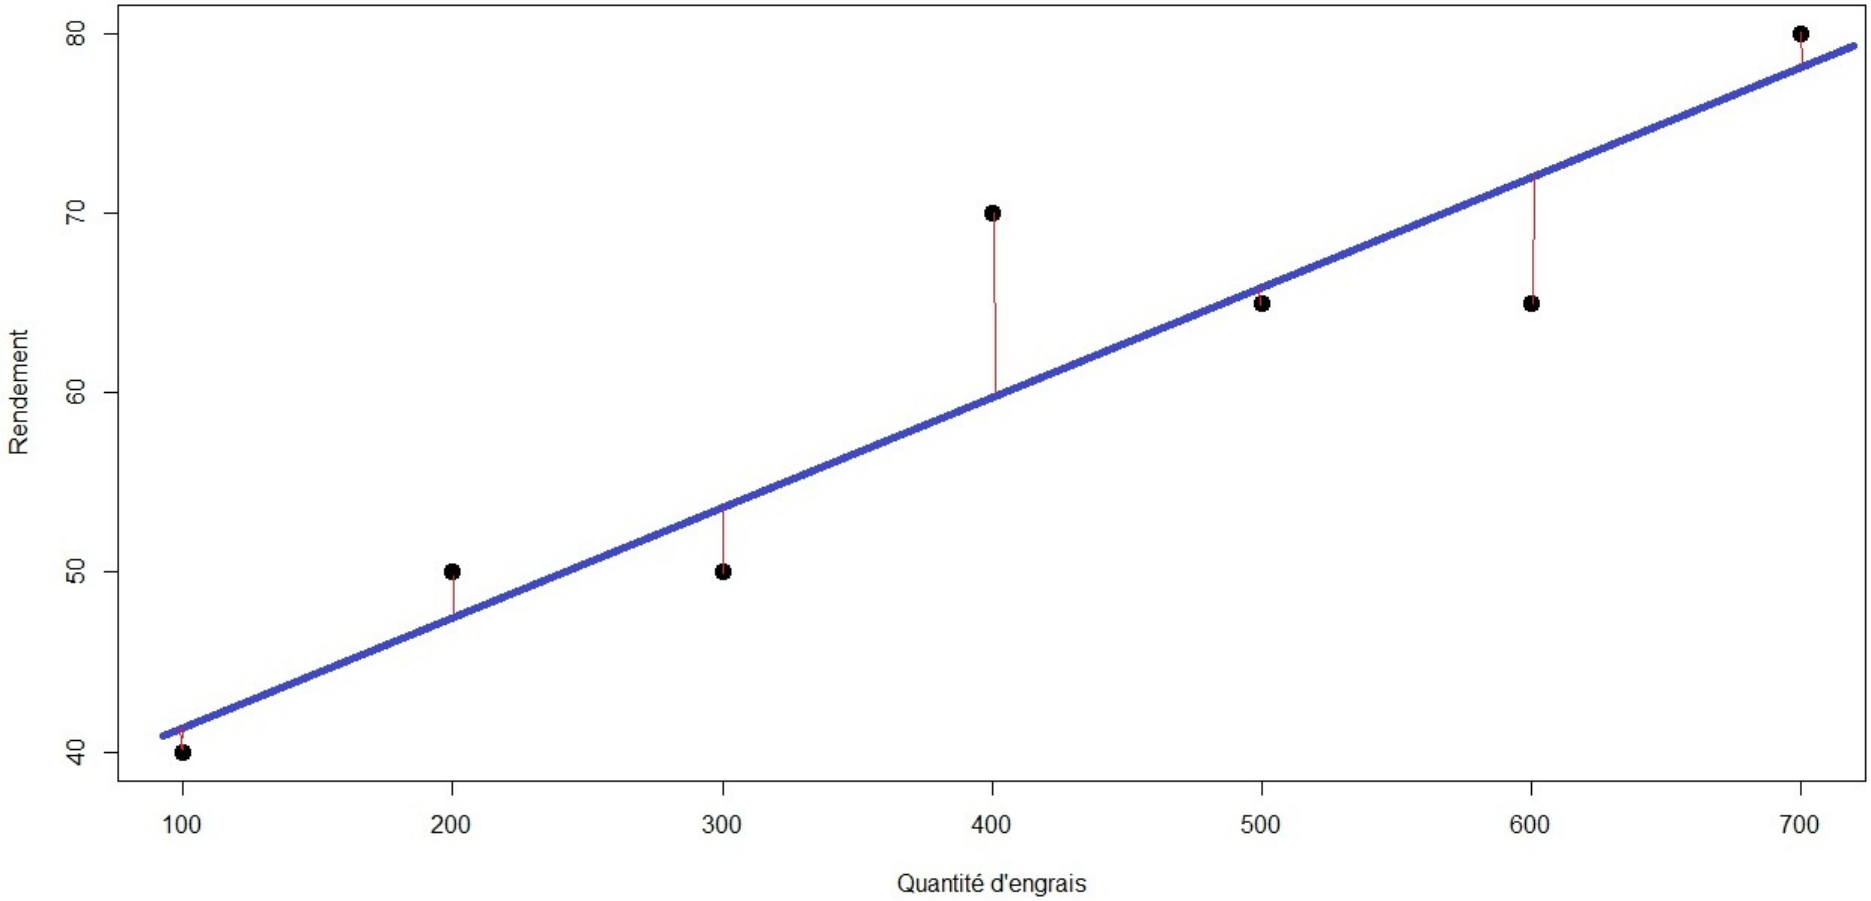
Rendement
40
50
60
70
80
100
200
300
400
500
600
700
Quantité d'engrais

Calcul des estimateurs de a et b

Les paramètres fixes du modèle $y_i = a\,x_i + b + \epsilon_i$ sont donnés par

1. **Estimateur de a :**

$$\widehat{a} = \frac{S_{xy}}{S_x^2}$$

2. **Estimateur de b :**

$$\widehat{b} = \overline{y} - \widehat{a}\,\overline{x}$$

- S_{xy} est la covariance empirique entre x et y. Elle est définie par

$$S_{xy} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$

- S_x^2 est la variance empirique des x_i

$$S_x^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \overline{x})^2$$

- $\overline{x}$ et $\overline{y}$ désignent respectivement la moyenne empirique de x et y.

Preuve

On utilise le fait que la fonction $f(a, b)$ est strictement convexe, donc elle admet un minimum en un point unique $\left(\widehat{a}, \widehat{b}\right)$ qui est obtenu en annulant les dérivées partielles de $f(a, b) = \sum_{i=1}^{n} (y_i - a\,x_i - b)^2$.

Droite de régression

Définition

La droite d'équation

$$y = \widehat{a}x + \widehat{b}$$

est appelée **droite de régression de y en x.**

Exemple

Calculons les estimations des paramètres fixes du modèle de l'exemple.

On a

$$y_i = ax_i + b + \epsilon_i$$

où x_i et y_i désignent respectivement la quantité d'engrais et celle du rendement de la $i^{\text{ième}}$ parcelle.

Exemple

Calculons les estimations des paramètres fixes du modèle de l'exemple.

On a

$$y_i = ax_i + b + \epsilon_i$$

où x_i et y_i désignent respectivement la quantité d'engrais et celle du rendement de la $i^{\text{ième}}$ parcelle.

$$\sum_{i=1}^{7} x_i = 2\,800, \quad \sum_{i=1}^{7} y_i = 420, \quad \sum_{i=1}^{7} x_i^2 = 1\,400\,000, \quad \sum_{i=1}^{7} x_i y_i = 184\,500$$

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 400, \quad \overline{y} = \frac{1}{n}\sum_{i=1}^{n} y_i = 60$$

$$\begin{aligned} S_x^2 &= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - (\overline{x})^2 = 40\,000 \\ S_{xy} &= \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \overline{x}\,\overline{y} = 2\,357.143 \end{aligned}$$

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 400, \quad \overline{y} = \frac{1}{n}\sum_{i=1}^{n} y_i = 60$$

$$\begin{aligned} S_x^2 &= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - (\overline{x})^2 = 40\,000 \\ S_{xy} &= \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \overline{x}\,\overline{y} = 2\,357.143 \end{aligned}$$

Par suite, les estimations des paramètres fixes sont :

$$\boxed{\widehat{a} = 0.05893 \qquad \widehat{b} = 36.428}$$

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

- **La pente estimée de la droite** $\widehat{a} = 0.05893$:

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

• **La pente estimée de la droite** $\widehat{a} = 0.05893$: une augmentation de la quantité d'angrais d'une unité (1 quintal) se traduit par une augmentation du rendement (en moyenne) de 0.05893 kg.

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

• **La pente estimée de la droite** $\widehat{a} = 0.05893$: une augmentation de la quantité d'angrais d'une unité (1 quintal) se traduit par une augmentation du rendement (en moyenne) de 0.05893 kg.

• **L'ordonnée à l'origine estimée** $\widehat{b} = 36.428$:

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

• **La pente estimée de la droite** $\widehat{a} = 0.05893$: une augmentation de la quantité d'angrais d'une unité (1 quintal) se traduit par une augmentation du rendement (en moyenne) de 0.05893 kg.

• **L'ordonnée à l'origine estimée** $\widehat{b} = 36.428$: Lorsqu'on ne met pas d'engrais (quantité d'engrais nulle), il faut s'attendre à un rendement moyen de 36.428 kg.

La droite de régression est donnée par

$$\boxed{y = 0.05893\,x + 36.428}$$

Interprétations

• **La pente estimée de la droite** $\widehat{a} = 0.05893$: une augmentation de la quantité d'angrais d'une unité (1 quintal) se traduit par une augmentation du rendement (en moyenne) de 0.05893 kg.

• **L'ordonnée à l'origine estimée** $\widehat{b} = 36.428$: Lorsqu'on ne met pas d'engrais (quantité d'engrais nulle), il faut s'attendre à un rendement moyen de 36.428 kg.

Attention

$\widehat{b}$ n'a pas toujours une interprétation. Par exemple, quantité moyenne d'eau par jour et rendement.

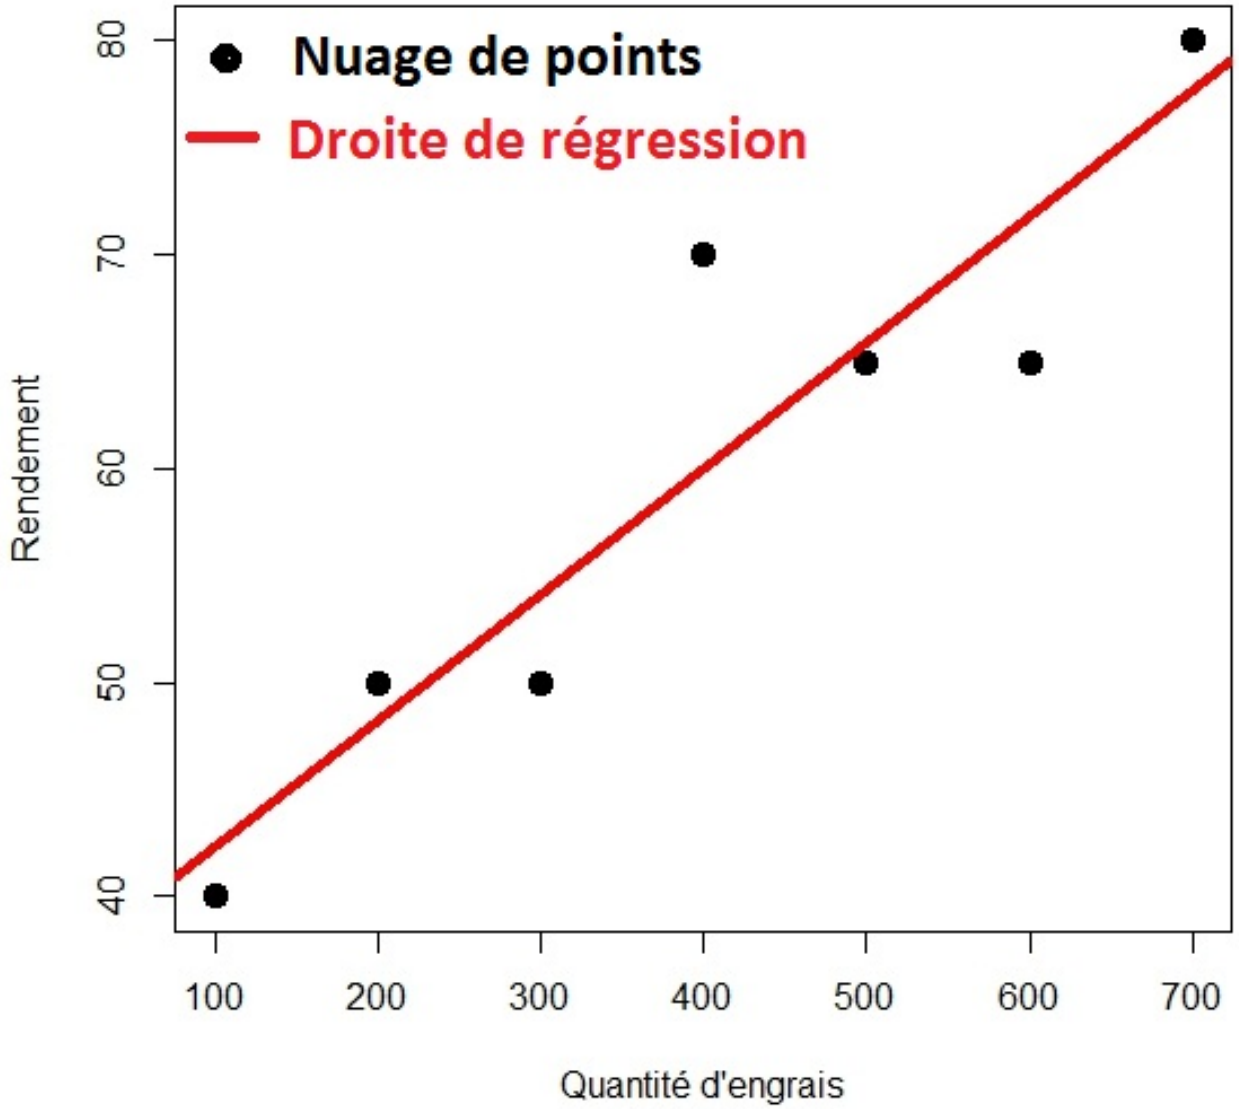
Nuage de points
Droite de régression
Rendement
40
50
60
70
80
100
200
300
400
500
600
700
Quantité d'engrais

Notations & Définitions

Pour un individu statistique donné,

- ☞ y_i : **valeur observée** ;
- ☞ $\widehat{y}_i = \widehat{a}\,x_i + \widehat{b}$: **valeur prédite** par le modèle ;
- ☞ $\widehat{\epsilon}_i = y_i - \widehat{y}_i$: **Résidu** (estimation des erreurs)

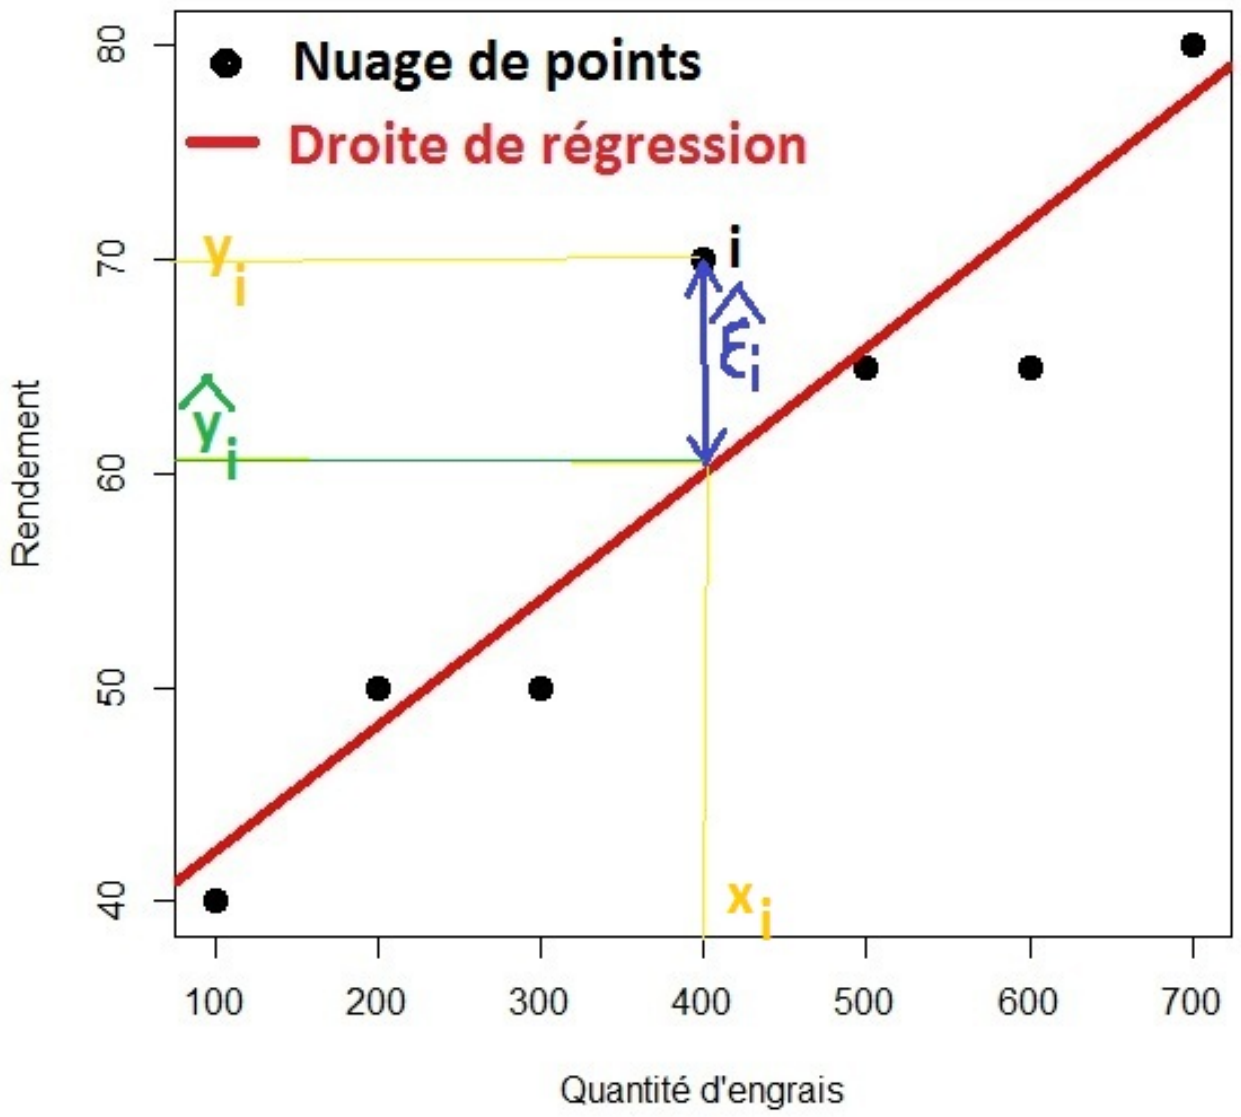
Nuage de points
Droite de régression
y_i
$\hat{y}_i$
i
$\hat{\varepsilon}_i$
x_i
Rendement
Quantité d'engrais
40
50
60
70
80
100
200
300
400
500
600
700

Remarque

- *La droite passe par le point moyen* $(\overline{x}, \overline{y})$.
- $\sum_{i=1}^{n} \widehat{\epsilon}_i = 0$.
- $\overline{\widehat{y}} = \overline{y}$.

Preuve

☞ Prouvons que la droite passe par le point moyen.

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

$$\sum_{i=1}^{n} \widehat{\epsilon}_i = \sum_{i=1}^{n} (y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(y_i - \widehat{a}x_i - \widehat{b} \right)$$

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

$$\sum_{i=1}^{n} \widehat{\epsilon}_i = \sum_{i=1}^{n} (y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(y_i - \widehat{a}x_i - \widehat{b}\right) = n\left[\overline{y} - \left(\widehat{a}\overline{x} + \widehat{b}\right)\right]$$

D'après le premier point, nous avons le résultat.

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

$$\sum_{i=1}^{n} \widehat{\epsilon}_i = \sum_{i=1}^{n} (y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(y_i - \widehat{a}x_i - \widehat{b}\right) = n\left[\overline{y} - \left(\widehat{a}\overline{x} + \widehat{b}\right)\right]$$

D'après le premier point, nous avons le résultat.

☞ Pour le dernier point,

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

$$\sum_{i=1}^{n} \widehat{\epsilon}_i = \sum_{i=1}^{n} (y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(y_i - \widehat{a}x_i - \widehat{b}\right) = n\left[\overline{y} - \left(\widehat{a}\overline{x} + \widehat{b}\right)\right]$$

D'après le premier point, nous avons le résultat.

☞ Pour le dernier point,

$$\overline{\widehat{y}} = \frac{1}{n}\sum_{i=1}^{n} \widehat{y}_i = \frac{1}{n}\sum_{i=1}^{n} \left(\widehat{a}x_i + \widehat{b}\right) = \widehat{a}\overline{x} + \widehat{b}$$

Preuve

☞ Prouvons que la droite passe par le point moyen.
La droite a pour équation : $y = \widehat{a}x + \widehat{b}$.
Pour $x = \overline{x}$, on a $y = \widehat{a}\overline{x} + \widehat{b}$. En remplaçant $\widehat{b}$ par son expression dans l'équation on aboutit au résultat.

☞ Montrons le deuxième point.

$$\sum_{i=1}^{n} \widehat{\epsilon}_i = \sum_{i=1}^{n} (y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(y_i - \widehat{a}x_i - \widehat{b}\right) = n\left[\overline{y} - \left(\widehat{a}\overline{x} + \widehat{b}\right)\right]$$

D'après le premier point, nous avons le résultat.

☞ Pour le dernier point,

$$\overline{\widehat{y}} = \frac{1}{n}\sum_{i=1}^{n} \widehat{y}_i = \frac{1}{n}\sum_{i=1}^{n} \left(\widehat{a}x_i + \widehat{b}\right) = \widehat{a}\overline{x} + \widehat{b}$$

On en déduit le résultat d'après le premier point.

Exemple

x_i	y_i	$\widehat{y}_i$	$\widehat{\epsilon}_i$
100	40	42.321	−2.321
200	50	48.214	1.786
300	50	54.107	−4.107
400	70	60.000	10.000
500	65	65.893	−0.893
600	65	71.786	−6.786
700	80	77.679	2.321

Variance résiduelle σ^2

Variance résiduelle σ^2

Le paramètre σ^2 représente la variance des erreurs résiduelles ϵ_i (non observables car paramètres inconnus).

Variance résiduelle σ^2

Le paramètre σ^2 représente la variance des erreurs résiduelles ϵ_i (non observables car paramètres inconnus).

Estimateur de σ^2

Un estimateur naturel de la variance résiduelle est donné par :

$$S_\epsilon^2 = \frac{1}{n-2}\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2 = \frac{1}{n-2}\sum_{i=1}^{n}\widehat{\epsilon}_i^2$$

Exemple

x_i	y_i	$\widehat{y}_i$	$\widehat{\epsilon}_i$	$\widehat{\epsilon}_i^2$
100	40	42.321	−2.321	5.389
200	50	48.214	1.786	3.189
300	50	54.107	−4.107	16.869
400	70	60.000	10.000	100.000
500	65	65.893	−0.893	0.797
600	65	71.786	−6.786	46.046
700	80	77.679	2.321	5.389

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Propriétés de S_ϵ^2

Théorème

- S_ϵ^2 *est un estimateur sans biais de* σ^2
- $\frac{(n-2)S_\epsilon^2}{\sigma^2}$ *suit une distribution du Khi-deux à* $(n-2)$ *degrés de liberté* (χ^2_{n-2}).
- S_ϵ^2 *est indépendant de* $\widehat{a}$, $\widehat{b}$ *et de* $\overline{y}$.

Propriétés de $\widehat{a}$ et de $\widehat{b}$

Théorème

- *$\widehat{a}$ et $\widehat{b}$ sont des estimateurs sans biais et convergents de a et de b.*
- *$\widehat{a}$ et $\widehat{b}$ suivent respectivement des lois normales d'espérance a et b et de variance*

$$var(\widehat{a}) = \frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \overline{x})^2}$$

$$var(\widehat{b}) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^{n}(x_i - \overline{x})^2} \right)$$

Puisque σ^2 est inconnue, donc il faut trouver des estimateurs de $var(\widehat{a})$ et $var(\widehat{b})$.

Puisque σ^2 est inconnue, donc il faut trouver des estimateurs de $var(\widehat{a})$ et $var(\widehat{b})$.

Propriété

- *En remplaçant σ^2 par S_ϵ^2, on obtient les estimateurs des variances :*

Puisque σ^2 est inconnue, donc il faut trouver des estimateurs de $var(\widehat{a})$ et $var(\widehat{b})$.

Propriété

- *En remplaçant σ^2 par S_ϵ^2, on obtient les estimateurs des variances :*

$$S_{\widehat{a}}^2 = \frac{S_\epsilon^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \quad et \quad S_{\widehat{b}}^2 = S_\epsilon^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right)$$

Puisque σ^2 est inconnue, donc il faut trouver des estimateurs de $var(\widehat{a})$ et $var(\widehat{b})$.

Propriété

- *En remplaçant σ^2 par S_ϵ^2, on obtient les estimateurs des variances :*

$$S_{\widehat{a}}^2 = \frac{S_\epsilon^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \quad et \quad S_{\widehat{b}}^2 = S_\epsilon^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right)$$

- *De plus,*

$$\frac{\widehat{a} - a}{S_{\widehat{a}}} \sim \mathcal{S}t(n-2) \quad et \quad \frac{\widehat{b} - b}{S_{\widehat{b}}} \sim \mathcal{S}t(n-2)$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Intervalles de confiance de a et b

Les estimations par intervalle de niveau de confiance $(1-\alpha)$ est :

Propriété

$$\begin{aligned} IC_{(1-\alpha)\%}(a) &= \left[\widehat{a} - t^{n-2}_{1-\alpha/2}\, S_{\widehat{a}}\ ;\ \widehat{a} + t^{n-2}_{1-\alpha/2}\, S_{\widehat{a}}\right] \\ IC_{(1-\alpha)\%}(b) &= \left[\widehat{b} - t^{n-2}_{1-\alpha/2}\, S_{\widehat{b}}\ ;\ \widehat{b} + t^{n-2}_{1-\alpha/2}\, S_{\widehat{b}}\right] \end{aligned}$$

où $t^{n-2}_{1-\alpha/2}$ est le quatile d'ordre $1-\alpha/2$ de la loi de Student à $n-2$ degrés de liberté.

Exemple des rendements agricoles

Donner les intervalles de confiance pour un niveau de 95%.

Exemple des rendements agricoles

Donner les intervalles de confiance pour un niveau de 95%.

- Calcul des variances

$\sum \widehat{\epsilon}_i^2 = 177.679$. La variance résiduelle est estimée à $S_\epsilon^2 = 35.5\,358$.

$\sum (x_i - \overline{x})^2 = 280\,000$, donc $S_{\widehat{a}}^2 = 0.000\,127$ et $S_{\widehat{b}}^2 = 25.38\,271$

$$S_{\widehat{a}} = 0.011\,265 \quad \text{et} \quad S_{\widehat{b}} = 5.038\,126$$

- Détermination du quantile : $t_{1-\alpha/2}^{n-2} = t_{0.975}^{5} = 2.570\,582$.

- Les intervalles :

$$IC_{95\%}(a) = [0.029\,969\ ;\ 0.087\,888] \quad \text{et} \quad IC_{95\%}(b) = [23.477\,660\ ;\ 49.379\,490]$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Test de nullité de l'ordonnée à l'origine

Pour un seuil de significativité α donné, on veut effectuer le test suivant :

Hypothèses

$$\begin{cases} H_0 & : \quad b = 0 \\ H_1 & : \quad b \neq 0 \end{cases}$$

Statistique de test et sa loi sous H_0

$$T = \frac{\widehat{b}}{S_{\widehat{b}}} \sim_{H_0} \mathcal{S}t(n-2)$$

Règle de décision

- Seuil critique sc : on rejette H_0 lorsque $|t_{obs}| > sc$.

$$sc = t_{1-\alpha/2}^{n-2}$$

- p-value pv : on rejette H_0 lorsque $pv < \alpha$.

$$pv = 2\left(1 - F_{\mathcal{S}t}\left(|t_{obs}|\right)\right)$$

$t_{1-\alpha/2}^{n-2}$ et $F_{\mathcal{S}t}$ désignent respectivement le quantile d'ordre $1-\alpha/2$ et la fonction de répartition de la loi de Student à $n-2$ degrés de liberté.

Exemple

On a :

$$\widehat{b} = 36.428 \text{ et } S_{\widehat{b}} = 5.038 \Rightarrow t_{obs} = 7.231$$

Le quantile d'ordre 0.975 de la loi de Student à 5 ddl est : $t^{5}_{0.975} = 2.5\,706$

Exemple

On a :

$$\widehat{b} = 36.428 \text{ et } S_{\widehat{b}} = 5.038 \Rightarrow t_{obs} = 7.231$$

Le quantile d'ordre 0.975 de la loi de Student à 5 ddl est : $t^5_{0.975} = 2.5\,706$

$t_{obs} > t^5_{0.975}$, donc on rejette l'hypothèse nulle.

Par suite, l'ordonnée à l'origine est significativement différente de zéro au seuil de 5%.

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Test de Student

On cherche à se prononcer sur le caractère significatif de la linéarité entre les données x_i et y_i.

Pour un seuil de significativité α donné, il s'agira de décider si la pente a de la droite de régression est significativement nulle.

On va donc tester, au seuil α

Hypothèses

$$\begin{cases} H_0 : & a = 0 \quad \text{(Absence de relation linéaire)} \\ H_1 : & a \neq 0 \quad \text{(Existence d'une relation linéaire)} \end{cases}$$

Test de Student

Statistique de test et sa loi sous H_0

$$T = \frac{\widehat{a}}{S_{\widehat{a}}} \sim_{H_0} \mathcal{S}t(n-2)$$

Test de Student

Statistique de test et sa loi sous H_0

$$T = \frac{\widehat{a}}{S_{\widehat{a}}} \sim_{H_0} \mathcal{S}t(n-2)$$

Règle de décision

- Seuil critique sc : on rejette H_0 lorsque $|t_{obs}| > sc$.

$$sc = t^{n-2}_{1-\alpha/2}$$

- p-value pv : on rejette H_0 lorsque $pv < \alpha$.

$$pv = 2\left(1 - F_{\mathcal{S}t}\left(|t_{obs}|\right)\right)$$

$t^{n-2}_{1-\alpha/2}$ et $F_{\mathcal{S}t}$ désignent respectivement le quantile d'ordre $1-\alpha/2$ et la fonction de répartition de la loi de Student à $n-2$ degrés de liberté.

Test de Student : Exemple

On a :

$$\widehat{a} = 0.055\,893 \text{ et } S_{\widehat{a}} = 0.011\,265 \Rightarrow t_{obs} = 5.231$$

Par ailleurs, le quantile d'ordre 0.975 de la loi de Student à 5 ddl est :
$t^5_{0.975} = 2.5\,706$

Test de Student : Exemple

On a :

$$\widehat{a} = 0.055\,893 \text{ et } S_{\widehat{a}} = 0.011\,265 \Rightarrow t_{obs} = 5.231$$

Par ailleurs, le quantile d'ordre 0.975 de la loi de Student à 5 ddl est : $t^5_{0.975} = 2.5\,706$

$t_{obs} > t^5_{0.975}$, donc on rejette l'hypothèse nulle.

Par suite, la liaison linéaire entre le rendement et la quantité d'engrais est significative au seuil de 5%.

Test de Fisher

Test de Fisher

On cherche à tester le caractère significatif de la linéarité entre x et y par comparaison.

Tester l'hypothèse $H_0 : a = 0$ contre l'hypothèse $H_1 : a \neq 0$, revient à comparer les modèles M_1 et M_2 définis par

$$\begin{aligned} M_1 : Y_i &= b + \epsilon_i,\ \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2) \\ M_2 : Y_i &= a\,x_i + b + \epsilon_i,\ \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2) \end{aligned}$$

M_1 est un sous modèle du modèle M_2.

Nous avons les hypothèses suivantes :

Test de Fisher

On cherche à tester le caractère significatif de la linéarité entre x et y par comparaison.

Tester l'hypothèse $H_0 : a = 0$ contre l'hypothèse $H_1 : a \neq 0$, revient à comparer les modèles M_1 et M_2 définis par

$$\begin{aligned} M_1 : Y_i &= b + \epsilon_i,\ \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2) \\ M_2 : Y_i &= a\,x_i + b + \epsilon_i,\ \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2) \end{aligned}$$

M_1 est un sous modèle du modèle M_2.

Nous avons les hypothèses suivantes :

Hypothèses

$$\begin{cases} H_0 : & \text{Modèle } M_1 \\ H_1 : & \text{Modèle } M_2 \end{cases}$$

Equation d'analyse de la variance

Décomposition de la somme des carrés totale

$$\sum_{i=1}^{n}(y_i-\overline{y})^2=\sum_{i=1}^{n}(\widehat{y}_i-\overline{y})^2+\sum_{i=1}^{n}(y_i-\widehat{y}_i)^2$$

- SCT $=\sum_{i=1}^{n}(y_i-\overline{y})^2$: somme des carrés totale représente la variabilité totale.
- SCM $=\sum_{i=1}^{n}(\widehat{y}_i-\overline{y})^2$: somme des carrés expliquée par le modèle.
- SCR $=\sum_{i=1}^{n}(y_i-\widehat{y}_i)^2$: somme des carrés résiduelle (des résidus).

Preuve de la décomposition de la SCT

Nous avons $SCT = \sum_{i=1}^{n} (y_i - \overline{y})^2$. Ajoutons et retranchons $\widehat{y}_i$ dans la sommation,

$$\begin{aligned}
\sum_{i=1}^{n} (y_i - \overline{y})^2 &= \sum_{i=1}^{n} [(\widehat{y}_i - \overline{y}) + (y_i - \widehat{y}_i)]^2 \\
&= SCM + SCR + 2 \sum_{i=1}^{n} (\widehat{y}_i - \overline{y})(y_i - \widehat{y}_i)
\end{aligned}$$

Preuve de la décomposition de la SCT

Nous avons $SCT = \sum_{i=1}^{n} (y_i - \overline{y})^2$. Ajoutons et retranchons $\widehat{y}_i$ dans la sommation,

$$\begin{aligned}\sum_{i=1}^{n} (y_i - \overline{y})^2 &= \sum_{i=1}^{n} [(\widehat{y}_i - \overline{y}) + (y_i - \widehat{y}_i)]^2 \\ &= SCM + SCR + 2\sum_{i=1}^{n} (\widehat{y}_i - \overline{y})(y_i - \widehat{y}_i)\end{aligned}$$

Or

$$\sum_{i=1}^{n} (\widehat{y}_i - \overline{y})(y_i - \widehat{y}_i) = \sum_{i=1}^{n} \left(\widehat{a}x_i + \widehat{b} - \overline{y}\right)\left(y_i - \widehat{a}x_i - \widehat{b}\right)$$

Puisque $\widehat{b} = \overline{y} - \widehat{a}\,\overline{x}$, donc

$$\begin{aligned}
\sum_{i=1}^{n} (\widehat{y}_i - \overline{y})(y_i - \widehat{y}_i) &= \sum_{i=1}^{n} (\widehat{a}x_i + \overline{y} - \widehat{a}\,\overline{x} - \overline{y})(y_i - \widehat{a}x_i - \overline{y} + \widehat{a}\,\overline{x}) \\
&= \widehat{a} \sum_{i=1}^{2} (x_i - \overline{x})\left[(y_i - \overline{y}) - \widehat{a}\,(x_i - \overline{x})\right] \\
&= \widehat{a}\, n\, S_{xy} - \widehat{a}^2\, n\, S_x^2 \\
&= n\,\widehat{a}\,\left(S_{xy} - \widehat{a}S_x^2\right)
\end{aligned}$$

Comme $\widehat{a} = \frac{S_{xy}}{S_x^2}$, alors cette somme est nulle.

Equation d'analyse de la variance

Décomposition de la variance totale

- Variance totale : $S_y^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i - \overline{y})^2$
- Variance de la régression : $S_{\widehat{y}}^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\widehat{y}_i - \overline{\widehat{y}}\right)^2 = \frac{1}{n}\sum_{i=1}^{n}(\widehat{y}_i - \overline{y})^2$
- Variance des résidus : $S_{\widehat{\epsilon}}^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\widehat{\epsilon}_i - \overline{\widehat{\epsilon}}\right)^2 = \frac{1}{n}\sum_{i=1}^{n}\widehat{\epsilon}_i^2$

$$\boxed{S_y^2 = S_{\widehat{y}}^2 + S_{\widehat{\epsilon}}^2}$$

Equation d'analyse de la variance

Décomposition de la variance totale

- Variance totale : $S_y^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i - \overline{y})^2$
- Variance de la régression : $S_{\widehat{y}}^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\widehat{y}_i - \overline{\widehat{y}}\right)^2 = \frac{1}{n}\sum_{i=1}^{n}(\widehat{y}_i - \overline{y})^2$
- Variance des résidus : $S_{\widehat{\epsilon}}^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\widehat{\epsilon}_i - \overline{\widehat{\epsilon}}\right)^2 = \frac{1}{n}\sum_{i=1}^{n}\widehat{\epsilon}_i^2$

$$\boxed{S_y^2 = S_{\widehat{y}}^2 + S_{\widehat{\epsilon}}^2}$$

✌ La variabilité totale est la somme de la variance expliquée et non expliquée par la régression.

Exemple

y_i	$\widehat{y}_i$	$(y_i - \overline{y})^2$	$(\widehat{y}_i - \overline{y})^2$	$(y_i - \widehat{y}_i)^2$
40	42.321	400	312.532	5.387
50	48.214	100	138.903	3.190
50	54.107	100	34.726	16.867
70	60.000	100	0.000	100.000
65	65.893	25	34.726	0.797
65	71.786	25	138.903	46.050
80	77.679	40	312.532	5.387
		SCT	SCM	SCR
		1150	972.321	177.679

Remarque

- $S^2_{\widehat{y}} = S^2_y \, r^2_{xy}$
- $S^2_{\widehat{\epsilon}} = S^2_y \left(1 - r^2_{xy}\right)$

Remarque

- $S^2_{\widehat{y}} = S^2_y \, r^2_{xy}$
- $S^2_{\widehat{\epsilon}} = S^2_y \left(1 - r^2_{xy}\right)$

En effet,

$$
\begin{aligned}
S^2_{\widehat{y}} &= \frac{1}{n}\sum_{i=1}^{n}\left(\widehat{a}\,x_i + \widehat{b} - \overline{y}\right)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}\left(\frac{S_{xy}}{S^2_x}\,x_i + \overline{y} - \frac{S_{xy}}{S_{xy}}\overline{x} - \overline{y}\right)^2 \\
&= \left(\frac{S_{xy}}{S^2_x}\right)^2 \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2 \\
&= \frac{(S_{xy})^2}{S^2_x}\,\frac{S^2_y}{S^2_y}
\end{aligned}
$$

Idem pour la deuxième remarque.

Test de Fisher

Statistique de test et sa loi sous H_O

$$F = \frac{SCM/1}{SCR/(n-2)} \sim_{H_O} \mathcal{F}(1, n-2)$$

Règle de décision

- Seuil critique sc : On rejette H_0 si $f_{obs} > sc$.

$$sc = f_{1-\alpha}^{1,n-2}$$

- p-value pv : $pv = 1 - F_{\mathcal{F}}(f_{obs})$

$f_{1-\alpha}^{1,n-2}$ et $F_{\mathcal{F}}$ désignent respectivement le quantile d'ordre $1-\alpha$ et la fonction de répartition de la loi de Fisher à 1 et $(n-2)$ ddl.

Table d'analyse de variance

Les résultats sont généralement présentés sous forme de tableau.

Source de variation	Degrés de liberté	Somme des Carrés (SC)	Carrés Moyens (CM)	Statistique de test	p-value
Modèle	1	SCM	$CMM = \frac{SCM}{1}$	$f_{obs} = \frac{CMM}{CMR}$	$\mathbb{P}(F > f_{obs})$
Résidus	$n-2$	SCR	$CMR = \frac{SCR}{n-2}$		
Total	$n-1$	SCT	$CMT = \frac{SCT}{n-1}$		

Test de Fisher : Exemple

$$F = \frac{SCM}{SCR/(n-2)} \Rightarrow f_{obs} = \frac{972.321}{(177.679/5)} = 27.3617$$

D'après la table de Fisher, la p-value vaut : $pv = 0.003379$.

$pv < 0.05$, donc on rejette l'hypothèse nulle.

Par conséquent, le modèle M_2 est pertinent.

Test de Fisher : Exemple

$$F = \frac{SCM}{SCR/(n-2)} \Rightarrow f_{obs} = \frac{972.321}{(177.679/5)} = 27.3617$$

D'après la table de Fisher, la p-value vaut : $pv = 0.003379$.

$pv < 0.05$, donc on rejette l'hypothèse nulle.

Par conséquent, le modèle M_2 est pertinent.

Nous avons le tableau d'analyse de variance suivant :

Test de Fisher : Exemple

$$F = \frac{SCM}{SCR/(n-2)} \Rightarrow f_{obs} = \frac{972.321}{(177.679/5)} = 27.3617$$

D'après la table de Fisher, la p-value vaut : $pv = 0.003379$.

$pv < 0.05$, donc on rejette l'hypothèse nulle.

Par conséquent, le modèle M_2 est pertinent.

Nous avons le tableau d'analyse de variance suivant :

Source	ddl	SC	CM	f_{obs}	pv
Modèle	1	972.321	972.321	27.362	0.003379
Résidus	5	177.679	35.536		
Total	6	1150	191.667		

Test Student vs test de Fisher

Les deux procédures du test de la linéarité sont équivalentes.

En effet, on utilise le fait que la loi du carré d'une distribution de Student à $(n-2)$ ddl est une distribution de Fisher à 1 et $(n-2)$ ddl.

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Coefficient de détermination R^2

Coefficient de détermination R^2

Définition

☞ *Le coefficient de détermination mesure la qualité d'ajustement du modèle : il mesure l'adéquation entre le modèle et les données observée.*

☞ *Il exprime la part de la variabilité de Y expliquée par le modèle.*

$$R^2 = \frac{SCM}{SCT}$$

Coefficient de détermination R^2

Définition

☞ *Le coefficient de détermination mesure la qualité d'ajustement du modèle : il mesure l'adéquation entre le modèle et les données observée.*

☞ *Il exprime la part de la variabilité de Y expliquée par le modèle.*

$$R^2 = \frac{SCM}{SCT}$$

Propriété

$$0 \leq R^2 \leq 1$$

Coefficient de détermination R^2

Définition

☞ *Le coefficient de détermination mesure la qualité d'ajustement du modèle : il mesure l'adéquation entre le modèle et les données observée.*

☞ *Il exprime la part de la variabilité de Y expliquée par le modèle.*

$$R^2 = \frac{SCM}{SCT}$$

Propriété

$$0 \leq R^2 \leq 1$$

Nous avons

$$SCT = SCM + SCR \Rightarrow 1 = \frac{SCM}{SCT} + \frac{SCR}{SCT}$$

$$\boxed{R^2 = \frac{SCM}{SCT} = 1 - \frac{SCR}{SCT}}$$

- Plus R^2 est proche de 1 meilleur est l'ajustement.
- R^2 faible traduit le fait que le modèle ne sert à rien.

Autrement dit, plus le coefficient de détermination se rapproche de 0, plus les points du nuage se dispersent autour de la droite de régression.

Au contraire, plus le R^2 tend vers 1, plus les points du nuage se resserrent autour de la droite de régression.
Quand les points sont exactement alignés sur la droite de régression, alors $R^2 = 1$.

Exemple

Calculons et interprétons le coefficient de détermination.

Exemple

Calculons et interprétons le coefficient de détermination.

- Après calcul, nous avons $R^2 = 0.8455$.
- On dit que 84.55% de la variabilté du rendement est expliquée par le modèle.

Remarque

- *Le coefficient de détermination est le carré du coefficient de corrélation linéaire.*
- $$F = \frac{SCM/1}{SCR/(n-2)} = \frac{R^2}{\frac{(1-R^2)}{n-2}} \sim \mathcal{F}(1, n-2)$$

Coefficient de détermination ajusté R_a^2

Coefficient de détermination ajusté R_a^2

Le coefficient de détermination R^2 est un estimateur biaisé qui surévalue la vraie qualité d'ajustement. En effet, le R^2 augmente avec le nombre de variables explicatives.

Pour corriger ce biais, on définit le coefficient de détermination ajusté R_a^2. Il permet de tenir compte du nombre d'observations et du nombre de variables explicatives.

$$R_a^2 = 1 - \frac{SCR/(n-p-1)}{SCT/(n-1)} = 1 - \left(\frac{n-1}{n-p-1}\right)(1-R^2)$$

Coefficient de détermination ajusté R_a^2

Le coefficient de détermination R^2 est un estimateur biaisé qui surévalue la vraie qualité d'ajustement. En effet, le R^2 augmente avec le nombre de variables explicatives.

Pour corriger ce biais, on définit le coefficient de détermination ajusté R_a^2. Il permet de tenir compte du nombre d'observations et du nombre de variables explicatives.

$$R_a^2 = 1 - \frac{SCR/(n-p-1)}{SCT/(n-1)} = 1 - \left(\frac{n-1}{n-p-1}\right)(1-R^2)$$

✌ R_a^2 permet de comparer le pouvoir explicatif de différents modèles.

Prévision : Position du problème

Prévision : Position du problème

On cherche à partir des données $(x_i, y_i)_{i=1,\cdots,n}$ à faire une prévision y_0 pour une nouvelle valeur x_0 non observée.

Intuitivement, on estime y_0 par $\widehat{y_0} = \widehat{a}\,x_0 + \widehat{b}$ qui est une estimation ponctuelle.

Prévision : Position du problème

On cherche à partir des données $(x_i, y_i)_{i=1,\cdots,n}$ à faire une prévision y_0 pour une nouvelle valeur x_0 non observée.

Intuitivement, on estime y_0 par $\widehat{y_0} = \widehat{a}\,x_0 + \widehat{b}$ qui est une estimation ponctuelle.

Comment donc évaluer la qualité de la prévision ?

- Intervalle de confiance de l'espérance de y en x_0.

$$IC\left(\mathbb{E}\left(y/_{x=x_0}\right)\right) \;:\; y_0 = ax_0 + b$$

- Intervalle de prévision (pari) pour y_0.

$$IP\left(y_0\right) \;:\; y_0 = ax_0 + b + \epsilon_0$$

Intervalle de confiance de l'espérance en x_0

Intervalle de confiance de l'espérance en x_0

Théorème

$\widehat{y}_0$ est un estimateur sans biais de $\mathbb{E}(y_0) = a\,x_0 + b$ de variance estimée

$$S_0^2 = S_{\widehat{\epsilon}}^2 \left(\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right)$$

De plus

$$\frac{\widehat{y}_0 - \mathbb{E}(y_0)}{S_0} \sim \mathcal{S}t(n-2)$$

Intervalle de confiance de l'espérance en x_0

Théorème

$\widehat{y}_0$ est un estimateur sans biais de $\mathbb{E}(y_0) = a\,x_0 + b$ de variance estimée

$$S_0^2 = S_{\widehat{\epsilon}}^2 \left(\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right)$$

De plus

$$\frac{\widehat{y}_0 - \mathbb{E}(y_0)}{S_0} \sim \mathcal{S}t(n-2)$$

Intervalle de confiance

$$IC_{(1-\alpha)}(\mathbb{E}(y_0)) = \left[\widehat{y}_0 - t_{1-\alpha/2}^{n-2}\, S_0 \;;\; \widehat{y}_0 + t_{1-\alpha/2}^{n-2}\, S_0 \right]$$

Remarque

En faisant varier x_0, les intervalles définissent deux hyperboles qui sont l'intervalle de confiance de la droite de régression.

Plus on s'éloigne du point moyen $(\overline{x}, \overline{y})$, moins l'estimation est précise.

Intervalle de prévision de y_0

Intervalle de prévision de y_0

Théorème

Pour une nouvelle valeur $x = x_0$, $\widehat{y}_0$ est un estimateur sans biais de y_0 de variance estmée

$$S_0'^2 = S_{\widehat{\epsilon}}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum_{i=1}^{n}(x_i - \overline{x})^2}\right)$$

De plus,

$$\frac{\widehat{y}_0 - y_0}{S_0'} \sim \mathcal{S}t(n-2)$$

Intervalle de prévision de y_0

Théorème

Pour une nouvelle valeur $x = x_0$, $\widehat{y}_0$ est un estimateur sans biais de y_0 de variance estmée

$$S_0'^2 = S_{\widehat{\epsilon}}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \overline{x})^2}{\sum_{i=1}^n (x_i - \overline{x})^2}\right)$$

De plus,

$$\frac{\widehat{y}_0 - y_0}{S_0'} \sim \mathcal{S}t(n-2)$$

Intervalle de prévision

$$IP_{(1-\alpha)}(y_0) = \left[\widehat{y}_0 - t_{1-\alpha/2}^{n-2}\, S_0' \; ; \; \widehat{y}_0 + t_{1-\alpha/2}^{n-2}\, S_0'\right]$$

Remarque

$$IC_{(1-\alpha)}(\mathbb{E}(y_0)) \subseteq IP_{(1-\alpha)}(y_0)$$

L'IP contient l'IC car il prend en compte l'erreur de modélisation.

Il est plus difficile de prédire une valeur particulière y_0 que l'espérance $\mathbb{E}(y_0/_{x=x_0})$.

Exemple

Exercice

Pour $x_0 = 325$, *faire une prévision et interpréter.*

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Analyse des résidus

Analyse des résidus

Objectif principal

☞ Permet de **valider** le modèle.

☞ Consiste à vérifier les hypothèses (conditions) des erreurs ϵ_i du modèle.

- Normalité
- Indépendance
- Homoscédasticité

Analyse des résidus

Objectif principal

☞ Permet de **valider** le modèle.

☞ Consiste à vérifier les hypothèses (conditions) des erreurs ϵ_i du modèle.

- Normalité
- Indépendance
- Homoscédasticité

Outils

☞ L'analyse se fait :

- De façon visuelle (graphes) ;
- En mettant en place des tests statistiques.

Analyse des résidus

Objectif principal

☞ Permet de **valider** le modèle.

☞ Consiste à vérifier les hypothèses (conditions) des erreurs ϵ_i du modèle.

- Normalité
- Indépendance
- Homoscédasticité

Outils

☞ L'analyse se fait :

- De façon visuelle (graphes) ;
- En mettant en place des tests statistiques.

N.B.

☞ Devrait être effectuée avant toute utilisation du modèle.

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimateur de a et b
     - Estimateur de la variance résiduelle σ^2
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Qualité du modèle
   - Test de nullité de l'ordonnée à l'origine
   - Tests du caractère significatif de la linéarité
     - Test de Student
     - Test de Fisher
   - Qualité globale
4. Prévision
5. Analyse des résidus
   - Objectif & outils
   - Vérification des conditions
6. Modèles dérivés

Analyse graphique principale

☞ On trace le nuage de point $(i, \widehat{\epsilon}_i)$, $i = 1, 2, \cdots, n$.

On admet que $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ si :

- le nuage de points n'a aucune structure particulière ;
- il y a une symétrie dans la répartition des points par rapport à l'axe des abscisses.

Analyse de la normalité

Graphique

• **Histogramme des résidus :** doit être symétrique, de classe modale autour de zéro.

• **QQ-plot :** On compare les quantiles des résidus estimés aux quantiles sous l'hypothèse de normalité.
Si les résidus ne sont pas distribuées suivant une loi normale, ils vont sécartés de la droie (droite d'Henry).

• etc.

Test statistique

• **Test de Shapiro-Wilk :** L'hypothèse de normalité est acceptée si la p-value est supérieure au seuil.

• **Test de Kolmogorov :** L'ypothèse de normalité est rejetée lorsque la p-value est inférieure au seuil de signification.

Analyse de l'indépendance

Graphique

• **Graphique « Scale-location » :** On trace le nuage des points $(\widehat{\epsilon}_i,\ y_i - \widehat{\epsilon}_i)$.
Si on ne peut pas ajuster le nuage de points par une droite, alors on n'admet que les ϵ_i et les x_i sont inépendantes.

Test de Durbin-Watson

On rejette l'hypothèse d'indépendance des résidus lorsque la p-value est inférieure au seuil.

Analyse de l'homoscédasticité

Graphique

• **Nuage de points** $(\widehat{y}_i, \widehat{\epsilon}_i)$ **:** Si une structure apparait, l'hypothèse d'homoscédasticité doit être remise en cause.
Parfois, une transformation des données $(\log(y), 1/y, \sqrt{y}, \cdots)$ permet de stabiliser la variance.

Test

• **Test de Breush-Pagan :** L'hypothèse d'homogénéité est rejetée si la p-value est inférieure au seuil.

• **Test de White :** Si le test est significatif, alors on accepte l'hypothèse d'hétéroscédasticité.

Modèles dérivés

Modèle log-linéaire : $y = b\,x^a$

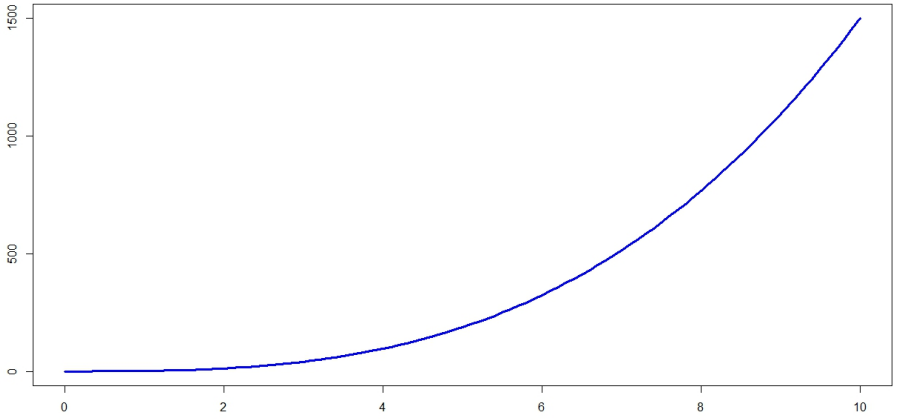

Modèle log-linéaire : $y = b\,x^a$

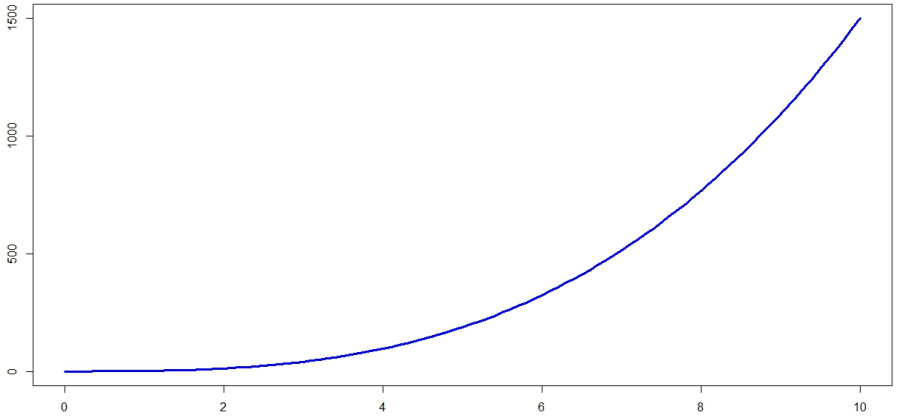

Linéarisation

$$ln(y) = aln(x) + ln(b)$$

Modèle exponentiel ou géométrique : $y = e^{ax+b}$

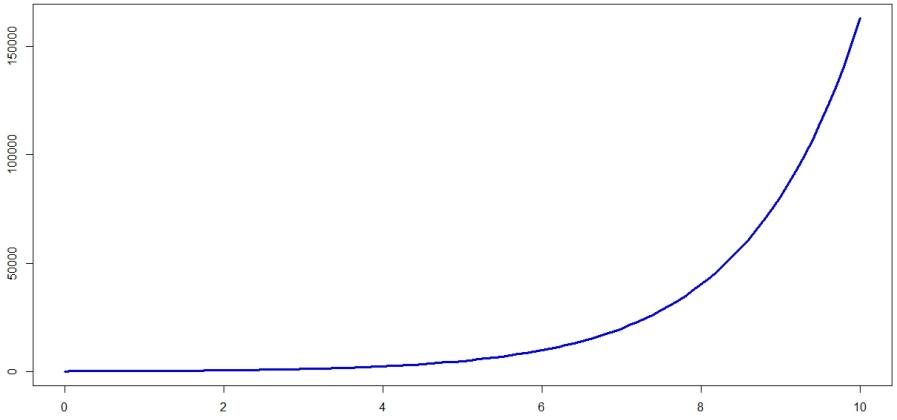

Modèle exponentiel ou géométrique : $y = e^{ax+b}$

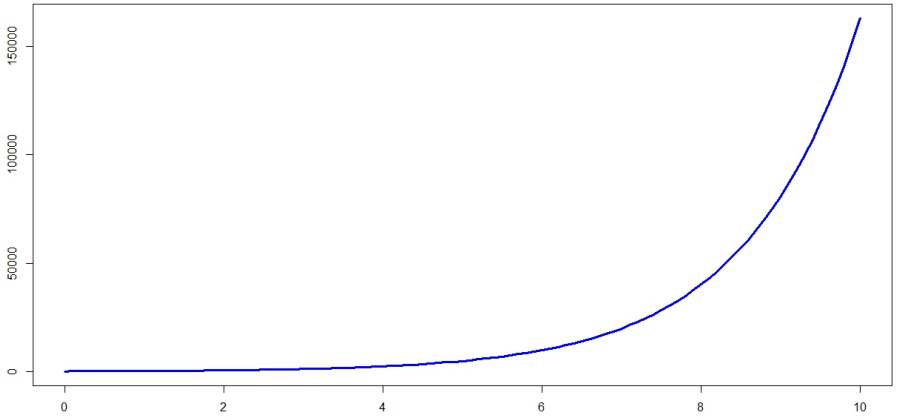

Linéarisation

$$ln(y) = ax + b$$

Modèle logarithmique : $y = a\,ln(x) + b$

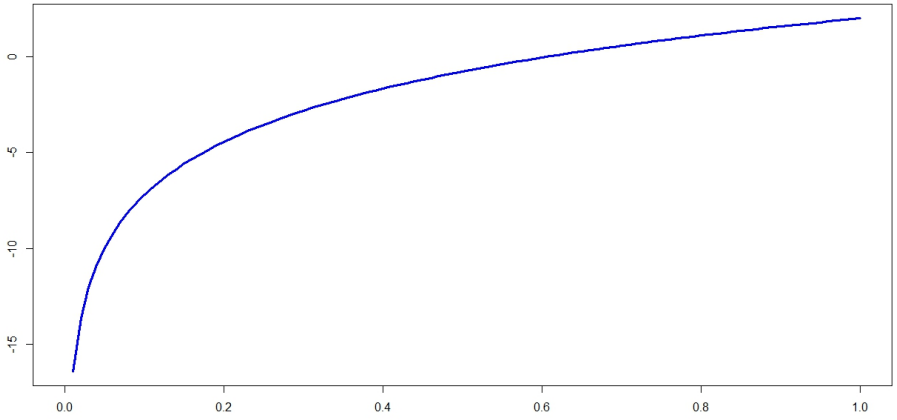

Modèle logarithmique : $y = a\,ln(x) + b$

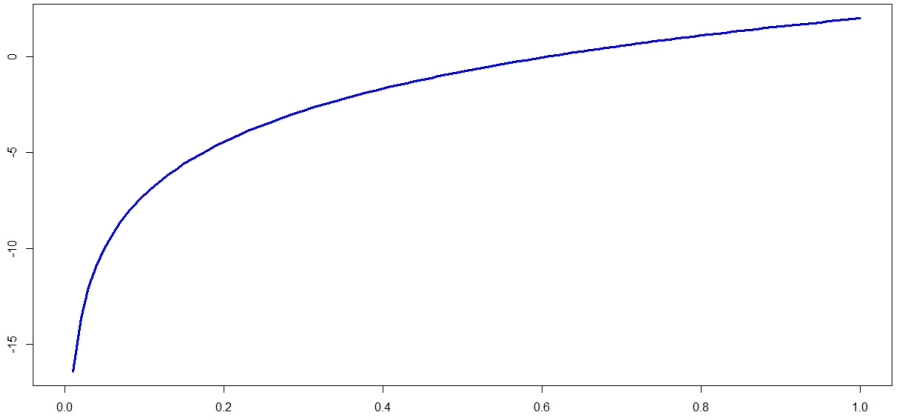

Linéarisation

$$y = aln(x) + b$$