Chapitre III : Modèle Linéaire Multiple

Dr. MERGANE

Université du Sine Saloum El-Hâdj Ibrahima NIASS

2024-2025

USSEIN

Chapitre III : Modèle Linéaire Multiple

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Introduction

☞ Généralisation du modèle linéaire simple.

☞ On dispose de n données multidimensionnelles $x_{i,1}, x_{i,2}, \cdots, x_{i,p}$, $i = 1, 2, \cdots, n$ et $p > 2$. Ces valeurs ne sont pas aléatoires.

☞ Nous disposons d'une variable aléatoire Y.

Définition

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p} + \epsilon_i$$

Les β_j sont les paramètres fixes du modèle.

β_j = L'impact de x_j sur y sans tenir compte de l'influence des autres : toutes choses égales par ailleurs.

Ecriture matricielle

$$\begin{cases} y_1 = & \beta_0 + \beta_1\, x_{1,1} + \beta_2\, x_{1,2} + \cdots + \beta_p\, x_{1,p} + \epsilon_1 \\ y_2 = & \beta_0 + \beta_1\, x_{2,1} + \beta_2\, x_{2,2} + \cdots + a_p\, x_{2,p} + \epsilon_2 \\ \vdots & \qquad\qquad \vdots \\ y_n = & \beta_0 + \beta_1\, x_{n,1} + \beta_2\, x_{n,2} + \cdots + \beta_p\, x_{n,p} + \epsilon_1 \end{cases}$$

En posant

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ 1 & x_{2,1} & \cdots & x_{2,p} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,p} \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

- $Y \in \mathbb{R}^n$
- $X \in \mathcal{M}(n, p+1)$ déterministe, de rang $p+1$ et $n > p+1$
- $\beta \in \mathbb{R}^p$ inconnu
- $\epsilon \in \mathbb{R}^n$

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ 1 & x_{2,1} & \cdots & x_{2,p} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,p} \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

- $Y \in \mathbb{R}^n$
- $X \in \mathcal{M}(n, p+1)$ déterministe, de rang $p+1$ et $n > p+1$
- $\beta \in \mathbb{R}^p$ inconnu
- $\epsilon \in \mathbb{R}^n$

$$Y = X\,\beta + \epsilon$$

Hypothèses

Nous avons les mêmes hypothèses qu'un modèle linéaire simple.

- **Normalité**
- **Indépendance**
- **Homoscédasticité**

$$\epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$$

$$\epsilon \sim \mathcal{N}_n(0, \sigma^2 I_n)$$

où I_n est la matrice identité.

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Estimation des paramètres fixes β

Les estimateurs des paramètres fixes du modèle peuvent être obtenus par la méthode des moindres carrés en minimisant en $\beta_0, \beta_1, \cdots, \beta_p$ la somme des carrés des erreurs.

$$f(\beta_0, \beta_1, \cdots, \beta_p) = \sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p})]^2$$

Estimation des paramètres fixes β

Les estimateurs des paramètres fixes du modèle peuvent être obtenus par la méthode des moindres carrés en minimisant en $\beta_0, \beta_1, \cdots, \beta_p$ la somme des carrés des erreurs.

$$f(\beta_0, \beta_1, \cdots, \beta_p) = \sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p})]^2$$

Estimateur

$$\widehat{\beta} = \left(X^t X\right)^{-1} X^t Y$$

Exemple (à la main)

Exercice

On considère les données suivantes :

i	Y	X_1	X_2
1	1	1	0
2	2	0	1
3	3	1	1

On veut estimer le modèle :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$$

Trouver les estimations des paramètres fixes du modèle.
En déduire le modèle estimé.

Exemple (avec logiciel)

Exercice

On étudie le rendement du riz (t/ha) en fonction de :

- X_1 : dose d'engrais (kg/ha)
- X_2 : indice de qualité du sol (de 1 à 5)

i	1	2	3	4	5	6	7
y	1.8	2.2	2.9	3.6	4.0	4.5	5.2
x_1	1	2	2	3	4	4	5
x_2	2	2	3	3	3	4	4

Le modèle estimé est : $\widehat{y} = .2 + .85x_1 + .6x_2$
Interpéter les effets.

Estimateur de σ^2

Un estimateur de la variance résiduelle est donné par

$$S_\epsilon^2 = \frac{1}{n-(p+1)} \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 = \frac{1}{n-p-1} \sum_{i=1}^{n} (\widehat{\epsilon}_i)^2$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Propriétés de $\widehat{\beta}$

- $\mathbb{E}(\widehat{\beta}) = \beta$
- $\mathbb{V}(\widehat{\beta}) = \sigma^2 \, (X^t \, X)^{-2}$

$$\frac{\widehat{\beta}_j - \beta_j}{S_\epsilon \sqrt{c_{jj}}} \sim \mathcal{S}t(n-p)$$

où c_{jj} est le terme (j, j) de la matrice $(X^t \, X)^{-1}$

Propriétés de S_ϵ^2

- $\mathbb{E}(S_\epsilon^2) = \sigma^2$
- $\frac{(n-p-1)\, S_\epsilon^2}{\sigma^2} \sim \chi^2_{n-p-1}$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Pour un paramètre β_j

Intervalle de confiance

$$IC_{1-\alpha}(\beta_j) = \left[\widehat{\beta}_j - t_{1-\alpha/2}^{n-p-1}\, S_\epsilon \sqrt{c_{jj}}\,;\, \widehat{\beta}_j + t_{1-\alpha/2}^{n-p-1}\, S_\epsilon \sqrt{c_{jj}}\right]$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Pour un paramètre β_j

Test statistique

Hypothèses

$$\begin{cases} H_0 & : \quad \beta_j = 0 \\ H_1 & : \quad \beta_j \neq 0 \end{cases}$$

La statistique de test et sa loi sous H_0

$$T = \frac{\widehat{\beta}_j}{s_\epsilon \sqrt{c_{jj}}} \sim_{H_0} \mathcal{S}t(n-p-1)$$

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Test de significativité du modèle

Hypothèses

$$\begin{cases} H_0 \ : \quad \beta_1 = \cdots = \beta_p = 0 \ \ (\text{Aucune des } p \text{ variables n'a une influence sur } Y) \\ H_1 \ : \quad \exists j \in \{1, \cdots, p\}, \beta_j \neq 0 \ (\text{Au moins une variable a une influence sur } Y) \end{cases}$$

Remarque

Sous H_0, $y_i = \beta_0 + \epsilon_i$.

Statistique de test et sa loi sous H_0

$$F = \frac{\sum_{i=1}^{n} (\widehat{y}_i - \overline{y})^2 / p}{\sum_{i=1}^{n} (y_i - \widehat{y}_i)^2 / (n-p)} = \frac{SCM/p}{SCR/(n-p-1)} \sim \mathcal{F}(p, n-p-1)$$

Table d'analyse de variance

Source de variation	Degrés de liberté	Somme des Carrés (SC)	Carrés Moyens (CM)	Statistique de test	p-value
Modèle	p	SCM	$CMM = \frac{SCM}{p}$	$f_{obs} = \frac{CMM}{CMR}$	$\mathbb{P}(F > f_{obs})$
Résidus	$n-(p+1)$	SCR	$CMR = \frac{SCR}{n-p-1}$		
Total	$n-1$	SCT	$CMT = \frac{SCT}{n-1}$		

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Test sur plusieurs coefficients

☞ On se demande si un nombre k de variables explicatives ne suffirait pas à expliquer Y, avec $k < p$.

☞ On va tester la nullité de $q \leq p$ paramètres.

Test sur plusieurs coefficients

☞ On se demande si un nombre k de variables explicatives ne suffirait pas à expliquer Y, avec $k < p$.

☞ On va tester la nullité de $q \leq p$ paramètres.

Hypothèses

$$\begin{cases} H_0 \ : \quad \beta_1 = \cdots = \beta_q = 0 \\ H_1 \ : \quad \exists j \in \{1, \cdots, q\}, \beta_j \neq 0 \end{cases}$$

Ce test revient à comparer deux modèles.

- Le modèle complet à p variables explicatives M_p pour lequel on évalue la somme des carrés des résidus SCR_p.
- Le modèle réduit à $p-q$ variables explicatives pour lequel on calcule la SCR notée SCR_{p-q}.

Statistique de test et sa loi sous H_0

$$F = \frac{(SCR_{p-q} - SCR_p)/q}{(SCR_{p-q})/(n-p-1)} \sim \mathcal{F}(q, n-p-1)$$

Si le test est significatif, alors il existe au moins une variable qui explique y au seuil α.

Plan

1. Introduction
2. Estimation des paramètres
   - Recherche des estimateurs
     - Estimation des paramètres fixes
     - Estimation de la variance résiduelle
   - Propriétés des estimateurs
   - Intervalles de confiance des paramètres
3. Tests dans le modèle de régression linéaire multiple
   - Test de significativeté d'un paramètre β_j
   - Test de significativité du modèle
   - Contribution jointe d'un ensemble de variables explicatives
   - Sélection de variables explicatives
     - Position du problème
     - Critères de R^2 et R_a^2
     - Critères AIC et BIC
     - Procédure pas à pas
4. Prévision

Position du problème

☞ Il sagit de trouver un groupe de variables suffisament explicatif.

☞ On cherche à trouver parmi les p variables explicatives, les $q \leq p$ variables les plus pertinentes.

Pour répondre à cette question, il faut :

- **Un critère** de qualité d'un modèle afin de comparer deux modèles n'ayant pas forcément le même nombre de variables explicatives.
- **Une procédure** qui permet de choisir parmi tous les modèles, le meilleur au sens de ce critère. C'est la procédure de choix du modèle.

Critères de R^2 et R_a^2

Le coefficient de détermination

$$R^2 = \frac{SCM}{SCT} = 1 - \frac{SCR}{SCT}$$

- Mesure l'ajustement du modèle aux données.
- Augmente avec le nombre de variables explicatives.
- Permet de comparer des modèles ayant le même nombre de variables

Le coefficient de détermination ajusté

$$R_a^2 = 1 - \frac{SCR/(n-p-1)}{SCT/(n-1)}$$

- N'augmente pas forcément avec le nombre de variables explicatives.
- Permet de comparer des modèles n'ayant pas le même nombre de variables

Critères AIC et BIC

- Akaike Information Criterion : $AIC = n\,ln\,(SCR) + 2\,k + cte$
- Bayesian Information Criterion : $AIC = n\,ln\,(SCR) + k\,ln(n) + cte$

Ces critères doivent être minimisés dans une procédure de choix.

k est le nombre de paramètres libres du modèle.
Dans un modèle linéaire multiple avec p variables explicatives nous avons comme paramètres $\beta_0, \beta_1, \cdots, \beta_p$ et σ^2 et une équation donc $k = p+1$ paramètres libres.

Procédure pas à pas ascendante (forward stepwise)

- On part du modèle nul sans variable.
- On effectue p régressions linéaires simples avec 2 variables explicatives et on sélectionne le modèle qui minimise le critère AIC.
- On affecte $p-1$ régressions linéaires avec 2 variables explicatives et on sélectionne le modèle qui minimise le critère AIC.
- On recommence jusqu'à ce que le critère AIC ne diminiue plus.

Procédure pas à pas descendante (backward stepwise)

- On part du modèle complet à p variables explicatives et on supprime pas à pas les variables.
- On arrête lorsque le critère AIC ne diminue plus.

Procédure stepwise

Principe

- Ascendante avec remise en cause à chaque étape des variables déjà introduites
- Permet d'éliminer les variables qui ne sont plus informatives compte tenu de celle qui vient d'être sélectionnée.

Prévision

Prévision

On souhaite prévoir

$$x_0 = (1, x_{1,0}, x_{2,0} \cdots, x_{p,0})^t \in \mathbb{R}^{+1}$$

D'après le modèle :

$$y_0 = x_0^t \beta + \epsilon_0$$

On remarque que

$$\mathbb{E}(\widehat{y}_0) = x_0 \, \beta^t$$

Sous les conditions précédentes :

Théorème

$$\frac{\widehat{y}_0 - \mathbb{E}\left(\widehat{y}_0\right)}{S_\epsilon \sqrt{x_0^t \left(X^t X\right)^{-1} x_0}} \sim \mathcal{S}t(n-p-1)$$

Théorème

$$\frac{\widehat{y}_0 - y_0}{S_\epsilon \sqrt{1 + x_0^t \left(X^t X\right)^{-1} x_0}} \sim \mathcal{S}t(n-p-1)$$

Pévision

Intervalle de confiance pour $\mathbb{E}(\widehat{y}_0)$

$$IC_{1-\alpha}(\mathbb{E}(\widehat{y}_0)) = \left[\widehat{y}_0 \pm t_{1-\alpha/2}^{n-p-1} S_\epsilon \sqrt{x_0^t (X^t X)^{-1} x_0}\right]$$

Intervalle de pari pour y_0

$$IP_{1-\alpha}(y_0) = \left[\widehat{y}_0 \pm t_{1-\alpha/2}^{n-p-1} S_\epsilon \sqrt{1 + x_0^t (X^t X)^{-1} x_0}\right]$$